

# STATISTICA E ANALISI DEI DATI

Capitolo 2 – Grafici di frequenza e contingenza

---


Dott. Stefano Cirillo  
Dott. Luigi Di Biasi

a.a. 2025-2026

# DISTRIBUZIONI DI FREQUENZA

---

- Per quanto riguarda la **distribuzione di frequenza**, consideriamo una variabile  $X$  e indichiamo con  $z_1, z_2, \dots, z_k$  le **modalità distinte** da essa assunte
  - Se la variabile  $X$ :
    - è **qualitativa** le modalità indicano delle qualità distinte degli individui
    - è **quantitativa** le modalità sono dei numeri reali distinti
- Consideriamo poi un campione  $(x_1, x_2, \dots, x_n)$  costituito da  $n$  osservazioni di  $X$ 
  - Se indichiamo con  $n_i$  il numero di volte in cui ciascuna osservazione  $z_i$  è presente nel campione, ossia la **frequenza assoluta** con cui essa appare nel campione, l'insieme  $\{(z_i, n_i), i = 1, 2, \dots, k\}$  si chiama **distribuzione di frequenza**




# DISTRIBUZIONI DI FREQUENZA

- Per quanto riguarda la **distribuzione di frequenza**, consideriamo una variabile  $X$  e indichiamo con  $z_1, z_2, \dots, z_k$  le **modalità distinte** da essa assunte
  - Se la variabile  $X$ :
    - è **qualitativa** le modalità indicano delle qualità distinte degli individui
    - è **quantitativa** le modalità sono dei numeri reali distinti
- Consideriamo poi un campione  $(x_1, x_2, \dots, x_n)$  costituito da  $n$  osservazioni di  $X$ 
  - Se indichiamo con  $n_i$  il numero di volte in cui ciascuna osservazione  $z_i$  è presente nel campione, ossia la **frequenza assoluta** con cui essa appare nel campione, l'insieme  $\{(z_i, n_i), i = 1, 2, \dots, k\}$  si chiama **distribuzione di frequenza**

4 4 4 2 1 0 1 3 2 3 3 2 1 2 0 1 4 3 1 0 0 4 1 1 2 0 1 1 3 4 4 4 0 3 3 4 4 0  
4 0 1 1 1 2 3 1 3 1 3 0 3 0 3 2 0 2 4 3 1 2 0 2 3 2 3 3 1 1 3 1 1 2 3 0 4  
3 4 3 2 4 1 3 3 1 4 3 2 3 2 1 4 4 2 4 4 1 3 2 0 1 3 4 4 3 4 4 3 1 1 4 0 3  
4 0 2 3 0 2 4 4 2 0 0 1 3 4 3 3 2 1 1 3 3 3 4 2 3 3 2 2 2 3 4 3 0 4 1 3 2  
3 2 3 1 4 4 4 3 2 3 0 0 4 4 0 1 4 0 1 0 0 4 1 3 3 4 2 2 0 4 0 1 1 3 4 3 3  
1 2 4 2 4 3 0 0 2 3 2 2 4 3 4 1 3 3 4 3 2 1 1 0 0 2 4 2 1 2 0 1 4 0 0 1 1  
3 4 2 0 3 1 0 1 1 0 1 2 4 4 2 3 3 0 3 4 2 2 4 1 0 0 3 0 1 4 2 4 0 4 1 1 1  
0 0 4 0 0 0 0 0 0 1 4 0 0 0 1 3 1 4 1 2 1 2 3 3 4 0 4 4 1 3 0 4 3 2 3 3 2  
1 1 1 0 1 4 3 4 2 2 3 0 0 2 4 3 4 1 0 1 3 3 0 3 4 1 3 2 4 3 4 3 0 4 3 0 1  
2 4 4 0 1 4 3 4 1 1 0 3 2 0 2 1 4 1 2 0 2 1 0 4 2 3 1 3 0 4 0 0 4 0 4 4 2  
2 1 0 1 2 1 1 4 0 1 2 2 2 4 1 0 2 0 1 2 3 4 3 4 3 1 1 0 4 1 4 1 1 4 2 1 0



Numero ordini	Frequenze assolute
$z_i$	$n_i$
0	78
1	87
2	68
3	86
4	88
<b>Totale</b>	<b>407</b>



# DISTRIBUZIONI DI FREQUENZA

- Esempio: La **distribuzione di frequenza** di variabili quantitative continue:

- Prendiamo adesso in esame una variabile continua come il fatturato mensile di 100 aziende
- Supponiamo inoltre che tali fatturati siano espressi in migliaia di euro e che sia stati raggruppati in classi
  - Allora, la tabella di frequenza è di questo tipo:



Fatturato mensile [ $z_i - z_{i+1}$ ]	Frequenze assolute $n_i$
0 - 10	30
10 - 20	15
20 - 40	25
40 - 70	20
70 - 100	10
<b>Totale</b>	<b>100</b>

Source

Source

4

# DISTRIBUZIONI DI FREQUENZA

- Esempio: La **distribuzione di frequenza** di **variabili quantitative** continue:

- Prendiamo adesso in esame una variabile continua come il fatturato mensile di 100 aziende
- Supponiamo inoltre che tali fatturati siano espressi in migliaia di euro e che sia stati raggruppati in classi
  - Allora, la tabella di frequenza è di questo tipo:



Fatturato mensile [ $z_i - z_{i+1}$ ]	Frequenze assolute $n_i$
0 - 10	30
10 - 20	15
20 - 40	25
40 - 70	20
70 - 100	10
<b>Totale</b>	<b>100</b>

Source

- Esempio: La **distribuzione di frequenza** di **variabili qualitative**:

- Immaginiamo di rilevare il colore degli occhi in una popolazione
- In questo caso la variabile **colore degli occhi** assume le modalità marroni, azzurri, neri e verdi e ciascuna di queste compare con una certa frequenza come mostra la tabella qui sotto:
  -



Colore occhi $z_i$	Frequenze assolute $n_i$
Marroni	18
Azzurri	45
Neri	89
Verdi	12
<b>Totale</b>	<b>164</b>

Source


# FREQUENZA RELATIVA

---

- Se non esistono dati mancanti, la somma delle frequenze assolute è sempre uguale alla numerosità del campione, ossia  $n = n_1 + n_2 + \dots + n_k$
- La **frequenza relativa** di un evento è il rapporto tra la frequenza assoluta di quell'evento e il numero totale di osservazioni o prove
  - Viene espressa come una frazione o una percentuale, e indica la proporzione con cui un determinato evento si verifica rispetto al totale

$$\text{Frequenza relativa} = \frac{\text{Numero totale di osservazioni}}{\text{Frequenza assoluta dell'evento}}$$

- O in altri termini:
$$f_i = \frac{n_i}{n} \quad (i = 1, 2, \dots, k)$$
- Senza dati mancanti la somma delle frequenze relative è sempre unitaria, ossia  $f_1 + f_2 + \dots + f_k = 1$



# DISTRIBUZIONI DI FREQUENZA

- Per una variabile qualitativa, in R la costruzione di una distribuzione di frequenza viene effettuata utilizzando la funzione `table()`
- La funzione `table()` in R crea una **tabella di contingenza** che mostra la frequenza (**assoluta**) degli elementi unici di un vettore o la combinazione di livelli di più variabili
  - **Definizione:** Una **tabella di contingenza** è una tabella che riassume la distribuzione congiunta di due o più variabili categoriali, mostrando le frequenze (assolute o relative) con cui si verificano le combinazioni dei livelli delle variabili

Colore occhi	Frequenze assolute
$z_i$	$n_i$
Marroni	18
Azzurri	45
Neri	89
Verdi	12
<b>Totale</b>	<b>164</b>

Source

# DISTRIBUZIONI DI FREQUENZA

---

- Ad esempio, consideriamo un campione di 36 elementi che costituiscono delle osservazioni di una variabile qualitativa *people* con quattro modalità (bambino, giovane, adulto, anziano):

```
> people <- c(rep("bambino",8),rep("giovane",3),rep("adulto",4), rep("giovane",9),rep("anziano",6),  
rep("bambino",2),rep("adulto",4))  
> people  
[1] "bambino" "bambino" "bambino" "bambino" "bambino" "bambino" "bambino"  
[9] "giovane" "giovane" "giovane" "adulto" "adulto" "adulto" "adulto" "giovane"  
[17] "giovane" "giovane" "giovane" "giovane" "giovane" "giovane" "giovane" "giovane"  
[25] "anziano" "anziano" "anziano" "anziano" "anziano" "anziano" "bambino" "bambino"  
[33] "adulto" "adulto" "adulto" "adulto"  
> table(people)  
people  
adulto anziano bambino giovane  
8       6      10     12
```

- Il comando **rep()** è usato per ripetere più volte le varie modalità nel vettore
- La funzione **table()** riporterà le modalità della variabile qualitativa che presentano un valore di frequenza assoluta diverso da zero.
  - Si nota che **table(people)** ordina le modalità della variabile qualitativa uomo in ordine alfabetico.

# DISTRIBUZIONI DI FREQUENZA


---

- Se si vuole ottenere la **distribuzione delle frequenze relative** basta utilizzare il comando:

```
> table(people)/length(people) #calcola le frequenze relative  
people  
adulto anziano bambino giovane  
0.2222222 0.1666667 0.2777778 0.3333333
```

- Se si prende in esame una **variabile ordinabile**, bisogna considerarla come un **fattore** e ordinare i livelli di questo fattore prima di costruire la distribuzione di frequenza
  - Riferendosi all'esempio precedente si ha:

```
> people_ordered <- ordered(people, levels=c("bambino","giovane","adulto","anziano"))  
> table(people_ordered)  
people_ordered  
bambino giovane adulto anziano  
10      12      8      6
```



# FREQUENZA ASSOLUTA CUMULATA

- La **frequenza assoluta cumulata** rappresenta il numero totale di osservazioni che hanno un valore inferiore o uguale a un determinato valore in un insieme di dati

- In altri termini: È la somma delle frequenze assolute fino a quel punto nella distribuzione.
- È definita come segue:

$$N_i = n_1 + n_2 + \cdots + n_i \quad (i = 1, 2, \dots, k)$$

- La frequenza assoluta cumulata fornisce un'idea di quante osservazioni si sono accumulate fino a un certo valore
  - Supponiamo di considerare un campione di osservazioni con le seguenti frequenze assolute

Valore	Frequenza Assoluta
1	2
2	5
3	8
4	10



Valore	Frequenza Assoluta Cumulata
1	2
2	2 + 5 = 7
3	7 + 8 = 15
4	15 + 10 = 23

# FREQUENZA RELATIVA CUMULATA

- La **frequenza relativa cumulata** è la proporzione (o percentuale) di osservazioni che hanno un valore inferiore o uguale a un determinato valore
  - In altri termini: È la somma delle frequenze relative fino a quel punto nella distribuzione
  - È definita come segue:

$$F_i = f_1 + f_2 + \cdots + f_i \quad (i = 1, 2, \dots, k)$$

- Continuando l'esempio precedente se il totale delle osservazioni è 25, la frequenza relativa cumulata sarà:

Valore	Frequenza Assoluta
1	2
2	5
3	8
4	10



Valore	Frequenza Relativa Cumulata
1	$\frac{2}{25} = 0.08$
2	$\frac{7}{25} = 0.28$
3	$\frac{15}{25} = 0.60$
4	$\frac{25}{25} = 1.00$

# DISTRIBUZIONI DI FREQUENZA

- Per calcolare le frequenze cumulate si deve utilizzare la funzione **cumsum()** che permette di calcolare le somme cumulate degli elementi di un vettore. Riferendoci all'esempio precedente, calcoliamo queste frequenze:

```
> cumsum(table(people))
adulto anziano bambino giovane
 8      14      24      36
> cumsum(table(people_ordered))
bambino giovane adulto anziano
 10      22      30      36
```

Frequenze Assolute Cumulate

```
> cumsum(table(people_ordered)/length(people_ordered))
bambino giovane adulto anziano
0.2777778 0.6111111 0.8333333 1.0000000
> cumsum(table(people)/length(people))
adulto anziano bambino giovane
0.2222222 0.3888889 0.6666667 1.0000000
```

Frequenze Relative Cumulate


# FREQUENZE DI INTERVALLI

- Le frequenze assolute e relative possono essere calcolate anche per variabili **quantitative** sempre che il numero di modalità distinte sia ben definito (es. i voti dal 18 al 30)
    - Spesso si preferisce **raccogliere le informazioni in classi** e calcolare le frequenze assolute o relative per classi, ossia le frequenze con cui gli elementi del vettore cadono nelle diverse classi.
    - **cut()** raggruppa i dati relativi ad un vettore in intervalli elencando nel parametro **breaks** gli estremi degli intervalli (aperti a sinistra e chiusi a destra)
      - Se desideriamo ottenere intervalli chiusi a sinistra e aperti a destra occorre specificare in **cut()** l'opzione **right = FALSE**
      - Calcoliamo la frequenza assoluta con cui un assegnato insieme di voti è suddiviso nelle quattro classi:

```
> # Creazione del vettore con i voti degli studenti  
> votiStudenti <- c(rep(18,6), rep(21,8), rep(25,10), rep(28,6),  
+                      rep(30,7), rep(25,2), rep(24,6), rep(25,4))  
> votiStudenti  
> sort(votiStudenti)
```

```
[1] 18 18 18 18 18 18 21 21 21 21 21 21 21 21 24 24 24 24 24 24 24 24 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 28 28 28 28 28 28 28 30 30 30 30 30 30 30 30
```

```
> table(cut(votiStudenti, breaks = c(17, 21, 24, 27, 31)))  
  
 (17,21] (21,24] (24,27] (27,31]  
    14       6      16      13
```



# FREQUENZE DI INTERVALLI

- Le frequenze assolute e relative possono essere calcolate anche per variabili **quantitative** sempre che il numero di modalità distinte sia ben definito (es. i voti dal 18 al 30)
    - Spesso si preferisce **raccogliere le informazioni in classi** e calcolare le frequenze assolute o relative per classi, ossia le frequenze con cui gli elementi del vettore cadono nelle diverse classi.
    - **cut()** raggruppa i dati relativi ad un vettore in intervalli elencando nel parametro **breaks** gli estremi degli intervalli (aperti a sinistra e chiusi a destra)
      - Se desideriamo ottenere intervalli chiusi a sinistra e aperti a destra occorre specificare in **cut()** l'opzione **right = FALSE**
      - Calcoliamo la frequenza assoluta con cui un assegnato insieme di voti è suddiviso nelle quattro classi:

```
> # Creazione del vettore con i voti degli studenti  
> votiStudenti <- c(rep(18,6), rep(21,8), rep(25,10), rep(28,6),  
+                   rep(30,7), rep(25,2), rep(24,6), rep(25,4))  
> votiStudenti  
> sort(votiStudenti)
```

```
> sort(votiStudenti)
[1] 18 18 18 18 18 18 21 21 21 21 21 21 21 21 21 24 24 24 24 24 24 24 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 25 28 28 28 28 28 28 30 30 30 30 30 30 30 30
```

```
> table(cut(votiStudenti, breaks = c(17, 21, 24, 27, 31)))  
  
(17,21] (21,24] (24,27] (27,31]  
14       6      16      13
```

```
> table(cut(votiStudenti, breaks = c(17, 21, 24, 27, 31), right=FALSE))  
  
[17,21) [21,24) [24,27) [27,31)  
       6        8       22      13
```

# FREQUENZE NEI DATI

- **Gestione dei dati mancanti:** Quando ci sono valori mancanti, si può usare la frequenza assoluta delle categorie per decidere come imputare i valori mancanti
  - Ad esempio, si può sostituire i valori mancanti con la categoria più frequente (moda) nei dati categoriali
- **Ribilanciamento dei dataset sbilanciati:** Nei problemi di classificazione binaria o multiclass, le frequenze relative delle classi vengono usate per identificare le classi sbilanciate
  - Applicando tecniche come il **downsampling** (ridurre il numero di campioni della classe maggioritaria) o **upsampling** (replicare i campioni della classe minoritaria)

	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	NaN
1	9	NaN	9.0	0	7.0
2	19	17.0	NaN	9	NaN

`df.fillna(0)`



	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	0.0
1	9	0.0	9.0	0	7.0
2	19	17.0	0.0	9	0.0

# FREQUENZE NEI DATI

- **Encoding di variabili categoriali:** Le frequenze relative delle categorie possono essere utilizzate per trasformare variabili categoriali in valori numerici, un processo chiamato **target encoding**
  - Questo è particolarmente utile per variabili con molte categorie, dove il semplice **one-hot** encoding potrebbe risultare inefficiente.

ID	Quartiere	Prezzo		ID	Quartiere (encoded)	Prezzo
1	A	300,000		1	325,000	300,000
2	B	450,000		2	475,000	450,000
3	A	350,000		3	325,000	350,000
4	C	600,000	→	4	575,000	600,000
5	B	500,000		5	475,000	500,000
6	C	550,000		6	575,000	550,000

# FREQUENZE NEI DATI

- `group_by(Quartiere)`
    - Raggruppa i dati per la colonna Quartiere
    - Crea gruppi separati per ogni valore unico nel quartiere

- `summarise(media_prezzo = mean(Prezzo))`
    - `summarise()`: Crea un nuovo dataframe riassuntivo
    - `media_prezzo = mean(Prezzo)`: Calcola la media della colonna Prezzo per ogni gruppo
    - Crea una nuova colonna chiamata media\_prezzo

# STATISTICA E ANALISI DEI DATI

Capitolo 2 – Grafici di Frequenza

---

Dott. Stefano Cirillo  
Dott. Luigi Di Biasi


a.a. 2025-2026

# BARPLOT PER LE FREQUENZE

- Consideriamo una variabile qualitativa  $X$  e indichiamo con  $z_1, z_2, \dots, z_k$  le modalità distinte da essa assunte. Consideriamo poi un campione  $x = (x_1, x_2, \dots, x_n)$  costituito da  $n$  osservazioni di  $X$ 
  - Disponiamo sull'asse orizzontale ed in modo equispaziato le modalità assunte da  $X$  e sull'asse verticale riportiamo le frequenze assolute o le frequenze relative
  - Tracciamo dei rettangoli (barre) centrati sulle modalità  $z_i$  tutti della stessa base e altezza pari alle frequenze (assolute o relative), ottenendo un grafico (o diagramma) a barre
  - Grafici di questo tipo sono di solito utilizzati per visualizzare i valori di una qualche quantità (ad esempio, la frequenza) per diverse modalità o categorie. In R si ottiene un grafico a barre utilizzando `barplot(table(x))`

```
> uomo<-c(rep("bambino",8),rep("giovane",3),rep("adulto",4),  
+ rep("giovane",9),rep("anziano",6),rep("bambino",2),rep("adulto"  
,4))  
>  
> barplot(table(uomo),col=1:4)
```


- Il parametro `col = 1:4` permette di colorare i rettangoli in modo differente



# BARPLOT PER LE FREQUENZE

- Da notare che le modalità della variabile uomo sono ordinate alfabeticamente.
  - Affinché le modalità siano ordinate in modo differente occorre trasformare il vettore uomo in un fattore uomo1.

```
> uomo1<-ordered(uomo ,levels=c("bambino","giovane","adulto","anziano"))
>
> barplot(table(ummo1),col=1:4)
```




# BARPLOT PER LE FREQUENZE

- Per la variabile qualitativa  $X$  è possibile anche costruire un grafico a bastoncini utilizzando il comando `plot(table(x))`:

```
> plot(table(uomo), col=1:4)
```

- Come prima, possiamo ordinare le modalità:

```
> uomo1<-ordered(uomo, levels=c("bambino", "giovane", "adulto", "anziano"))
> plot(table(umero1), col=1:4)
```




# BARPLOT PER LE FREQUENZE

- Se si desidera un grafico a bastoncini che riporti le frequenze relative si può utilizzare il comando `plot(table(x)/length(x))`

```
> uomo1<-ordered(uomo,levels=c("bambino","giovane","adulto","anziano"))
>
> plot(table(ummo1)/length(ummo1),col=1:4)
```

- Si possono anche realizzare grafici a barre per variabili qualitative ordinabili utilizzando la funzione `plot()` invece della funzione `barplot()`. Ad esempio, se si considera il titolo finale di studio posseduto da un campione di 75 persone:

```
> titolo<-c(rep("nessuno",5),rep("elementare",15),rep("media",25),
+ rep("diploma",20),rep("laurea",10))
>
> titoloFinale<-ordered(titolo,levels=c("nessuno","elementare",
+ "media","diploma","laurea"))
>
> plot(titoloFinale,xlab="Titolo finale di studi posseduti",col
=1:5)
```



# PIE CHART

---


- Un altro tipo di rappresentazione si ottiene mediante i **diagrammi a torta** che permettono di attribuire ciascuna modalità della variabile qualitativa in esame ad un settore circolare di un cerchio, la cui ampiezza è proporzionale alle frequenze
- I diagrammi a torta sono **quindi utili quando i dati non sono numerici ma categorici.**
- Un grafico a torta si costruisce tracciando un cerchio e suddividendolo in tanti settori circolari (fette o spicchi) quante sono le modalità distinte di dati
  - ogni settore ha un angolo al centro proporzionale alla frequenza (relativa o assoluta) della modalità corrispondente.
- Il sistema R sceglie il tipo di diagramma a torta con i diversi settori colorati differentemente utilizzando il comando pie(table(x)). Riferendoci all'esempio precedente:

```
> titolo<-c(rep("nessuno",5),rep("elementare",15),rep("media",25),  
+ rep("diploma",20),rep("laurea",10))  
> pie(table(titolo))
```

# PIE CHART

- Otteniamo quindi un diagramma suddiviso in 5 settori
- Si può anche scegliere un tratteggio particolare da utilizzare nei diagrammi a torta per tratteggiare differentemente i diversi settori utilizzando i comandi **density** = e **angle** = .

```
> pie(table(titolo), density=10, angle=15+10*(1:5), col=1:5)
```




# PIE CHART

- Otteniamo quindi un diagramma suddiviso in 5 settori
- Si può anche scegliere un tratteggio particolare da utilizzare nei diagrammi a torta per tratteggiare differentemente i diversi settori utilizzando i comandi **density** = e **angle** = .

```
> pie(table(titolo), density=10, angle=15+10*(1:5), col=1:5)
```

- Si nota che i cinque settori sono stati tratteggiati differentemente utilizzando delle linee ugualmente distanziate e inclinate opportunamente con angolazioni di 25, 35, 45, 55, 65 gradi.



# ESEMPIO

---

- Costruiamo ora un diagramma a torta per il titolo di studio dal campione di 75 individui utilizzando i valori percentuali.

```
> titolo<-c(rep("nessuno",5),rep("elementare",15),rep("media",25),
+ rep("diploma",20),rep("laurea",10))

> freqRel<-table(titolo)/length(titolo)
> freqRel # visualizza le frequenze relative
titolo
  diploma elementare      laurea      media      nessuno
0.26666667 0.20000000 0.13333333 0.33333333 0.06666667
>
> percentuali<-freqRel*100
> percentuali # visualizza le percentuali
titolo
  diploma elementare      laurea      media      nessuno
26.666667 20.000000 13.333333 33.333333 6.666667
> sum(percentuali)
[1] 100
>
> perc<-round(percentuali)
> labelP<-c("diploma","elementare","laurea","media","nessuno")
> labelP<-paste(labelP,perc)
> labelP<-paste(labelP,"%",sep="")
> pie(percentuali,label=labelP, col=rainbow(length(labelP)),
+ main="Valori percentuali")
```

# ESEMPIO

- Costruiamo ora un diagramma a torta per il titolo di studio dal campione di 75 individui utilizzando i valori percentuali.

```
> titolo<-c(rep("nessuno",5),rep("elementare",15),rep("media",25),  
+ rep("diploma",20),rep("laurea",10))  
  
> freqRel<-table(titolo)/length(titolo)  
> freqRel # visualizza le frequenze relative  
titolo  
    diploma elementare      laurea       media     nessuno  
0.26666667 0.20000000 0.13333333 0.33333333 0.06666667  
>  
> percentuali<-freqRel*100  
> percentuali # visualizza le percentuali  
titolo  
    diploma elementare      laurea       media     nessuno  
 26.666667 20.000000 13.333333 33.333333 6.666667  
> sum(percentuali)  
[1] 100  
>  
> perc<-round(percentuali)  
> labelP<-c("diploma","elementare","laurea","media","nessuno")  
> labelP<-paste(labelP,perc)  
> labelP<-paste(labelP,"%",sep="")  
> pie(percentuali,label=labelP, col=rainbow(length(labelP)),  
+ main="Valori percentuali")
```

- Usiamo `round()` per arrotondare i numeri

# ESEMPIO

- Costruiamo ora un diagramma a torta per il titolo di studio dal campione di 75 individui utilizzando i valori percentuali.

```
> titolo<-c(rep("nessuno",5),rep("elementare",15),rep("media",25),
+ rep("diploma",20),rep("laurea",10))

> freqRel<-table(titolo)/length(titolo)
> freqRel # visualizza le frequenze relative
titolo
  diploma elementare      laurea       media     nessuno
0.26666667 0.20000000 0.13333333 0.33333333 0.06666667
>
> percentuali<-freqRel*100
> percentuali # visualizza le percentuali
titolo
  diploma elementare      laurea       media     nessuno
26.666667 20.000000 13.333333 33.333333 6.666667
> sum(percentuali)
[1] 100
>
> perc<-round(percentuali)
> labelP<-c("diploma","elementare","laurea","media","nessuno")
> labelP<-paste(labelP,perc)
> labelP<-paste(labelP,"%",sep="")
> pie(percentuali,label=labelP, col=rainbow(length(labelP)),
+ main="Valori percentuali")
```

- Usiamo `round()` per arrotondare i numeri
- `label()` definisce le etichette

# ESEMPIO

- Costruiamo ora un diagramma a torta per il titolo di studio dal campione di 75 individui utilizzando i valori percentuali.

```
> titolo<-c(rep("nessuno",5),rep("elementare",15),rep("media",25),
+ rep("diploma",20),rep("laurea",10))

> freqRel<-table(titolo)/length(titolo)
> freqRel # visualizza le frequenze relative
titolo
  diploma elementare      laurea       media     nessuno
0.26666667 0.20000000 0.13333333 0.33333333 0.06666667
>
> percentuali<-freqRel*100
> percentuali # visualizza le percentuali
titolo
  diploma elementare      laurea       media     nessuno
26.666667 20.000000 13.333333 33.333333 6.666667
> sum(percentuali)
[1] 100
>
> perc<-round(percentuali)
> labelP<-c("diploma","elementare","laurea","media","nessuno")
> labelP<-paste(labelP,perc)
> labelP<-paste(labelP,"%",sep="")
> pie(percentuali,label=labelP, col=rainbow(length(labelP)),
+ main="Valori percentuali")
```

- Usiamo `round()` per arrotondare i numeri
- `label()` definisce le etichette
- `paste()` serve a concatenare stringhe

# ESEMPIO

- Costruiamo ora un diagramma a torta per il titolo di studio dal campione di 75 individui utilizzando i valori percentuali.

```
> titolo<-c(rep("nessuno",5),rep("elementare",15),rep("media",25),
+ rep("diploma",20),rep("laurea",10))

> freqRel<-table(titolo)/length(titolo)
> freqRel # visualizza le frequenze relative
titolo
  diploma elementare      laurea       media     nessuno
0.26666667 0.20000000 0.13333333 0.33333333 0.06666667
>
> percentuali<-freqRel*100
> percentuali # visualizza le percentuali
titolo
  diploma elementare      laurea       media     nessuno
26.666667 20.000000 13.333333 33.333333 6.666667
> sum(percentuali)
[1] 100
>
> perc<-round(percentuali)
> labelP<-c("diploma","elementare","laurea","media","nessuno")
> labelP<-paste(labelP,perc)
> labelP<-paste(labelP,"%",sep="")
> pie(percentuali,label=labelP, col=rainbow(length(labelP)),
+ main="Valori percentuali")
```

- Usiamo `round()` per arrotondare i numeri
- `label()` definisce le etichette
- `paste()` serve a concatenare stringhe
- `sep=` è il separatore tra le stringhe

# ESEMPIO

- Costruiamo ora un diagramma a torta per il titolo di studio dal campione di 75 individui utilizzando i valori percentuali.

```
> titolo<-c(rep("nessuno",5),rep("elementare",15),rep("media",25),
+ rep("diploma",20),rep("laurea",10))


> freqRel<-table(titolo)/length(titolo)
> freqRel # visualizza le frequenze relative
titolo
  diploma elementare      laurea       media     nessuno
0.26666667 0.20000000 0.13333333 0.33333333 0.06666667
>
> percentuali<-freqRel*100
> percentuali # visualizza le percentuali
titolo
  diploma elementare      laurea       media     nessuno
26.666667 20.000000 13.333333 33.333333 6.666667
> sum(percentuali)
[1] 100
>
> perc<-round(percentuali)
> labelP<-c("diploma","elementare","laurea","media","nessuno")
> labelP<-paste(labelP,perc)
> labelP<-paste(labelP,"%",sep="")
> pie(percentuali,label=labelP, col=rainbow(length(labelP)),
+ main="Valori percentuali")
```

- Usiamo `round()` per arrotondare i numeri
- `label()` definisce le etichette
- `paste()` serve a concatenare stringhe
- `sep=` è il separatore tra le stringhe
- `rainbow()` è un modo alternativo per selezionare i colori

# GRAFICI DI FREQUENZA E CONTINGENZA

- Per rappresentare invece correttamente la distribuzione di frequenza di una variabile quantitativa  $X$  occorre utilizzare il comando `plot(table(x))`.
- Esso produce un grafico a bastoncini in cui sull'asse orizzontale sono riportati i valori e sull'asse verticale le frequenze assolute dei valori distinti assunti nel vettore. Riferendosi ai voti di 30 studenti universitari si ha:


```
> voti<-c(18,19,20,30,29,28,21,22,23,27,26,25,24,25,  
+ 26,24,23,22,27,28,21,24,25,25,27,19,21,28,29,28)  
> plot(table(voti),ylab="Frequenza dei voti di 30 studenti  
universitari", col=1:13)
```



# GRAFICI DI FREQUENZA E CONTINGENZA

- Per variabili quantitative si può anche considerare una rappresentazione tramite diagrammi a torta attraverso il comando `pie(table(x))`, dove  $x$  è un vettore o un fattore, anche se tale grafico non si rivela spesso utile.

```
> pie(table(voti), col = rainbow(13), radius = 0.9, xlab="Voti di  
30 studenti universitari")
```



# STATISTICA E ANALISI DEI DATI

Capitolo 2 – Tabelle di contingenza

---

Dott. Stefano Cirillo  
Dott. Luigi Di Biasi

a.a. 2025-2026

# BREVE RECAP

---

- **Variabili (osservabili)**
  - Variabili quantitative
  - Variabili qualitative
- **Modalità (distinte)**
  - Frequenza assoluta
  - Frequenza relativa
  - frequenza assoluta cumulata
  - frequenza relativa cumulata
- **Distribuzione di frequenza**
  - distribuzione di frequenza relativa
  - distribuzione di frequenza assoluta

# BREVE RECAP

---

- **Frequenza congiunta**

- Tabelle di contingenza (o tabella a due vie, o cross-tab)
- Distribuzione di frequenza marginale
- Frequenze relative congiunte
- Frequenze relative marginali
- Grafici per tavelle di contingenza

# FREQUENZA CONGIUNTA

---

Consideriamo una popolazione composta da «persone» di sesso diverso e un insieme di «bevande distinte».

Ipotizziamo di «contare» quante volte le persone di sesso X bevono caffè oppure tè!

In questo modo, possiamo rispondere a domande del tipo «Quante persone stanno insieme in due categorie specifiche?»

# FREQUENZA CONGIUNTA

---

La definizione di frequenza congiunta ci permette di rispondere a domande come la precedente.

## Definizioni (informali):


- **la frequenza congiunta assoluta** è il numero di individui che rientrano contemporaneamente in due categorie (es. donne e caffè).
- **La frequenza congiunta relativa** è la stessa quantità divisa per il totale degli individui (una percentuale).

# TABELLA DI CONTINGENZA

---

Una *tabella di contingenza* riassume la distribuzione congiunta di due o più variabili categoriali, mostrando le frequenze (assolute o relative) con cui si verificano le combinazioni dei livelli delle variabili.

- Ci permette di «valutare» eventuali legami tra due variabili  $X$  e  $Y$  rilevate congiuntamente sugli stessi individui;
- Queste tabelle riassumono la distribuzione congiunta e permettono di valutare l'associazione tra le categorie




# TABELLA DI CONTINGENZA

In una tabella di contingenza, **ogni cella contiene una frequenza congiunta.**

I totali di riga e di colonna sono le **frequenze marginali**.

	Tè	Cattè	Totale
Donne	30	20	50
Jomini	25	25	50
Totale	55	45	100



# TABELLA DI CONTINGENZA

---

Domande per voi:

- Perché solo variabili categoriali?
- Perché è necessario che le variabili siano rilevate congiuntamente sugli stessi individui?
- Per le variabili **quantitative** che strumenti usiamo?

# TABELLE DI CONTINGENZA

---

## Definizioni:

- Sia  $X$  una variabile e indichiamo con  $x_1, x_2, \dots, x_h$  le modalità distinte da essa assunte e sia  $Y$  un'altra variabile e indichiamo con  $y_1, y_2, \dots, y_k$  le modalità distinte da essa assunte
- Consideriamo un campione  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$  costituito da  $n$  osservazioni di  $(X, Y)$ 
  - L'elemento  $n_{ij}$  in posizione  $(i, j)$  della tabella di contingenza, detto **frequenza congiunta**, rappresenta il numero di volte in cui una particolare coppia di modalità  $(x_i, y_j)$  si presenta nel campione.

# TABELLE DI CONTINGENZA

---


## Definizioni:

- Dalla tabella è possibile ottenere la **distribuzione di frequenza marginale di  $X$** :

$$n_{\cdot j} = \sum_{i=1}^h n_{i,j} \quad (j = 1, 2, \dots, k)$$


- Mentre la **distribuzione di frequenza marginale di  $Y$**  è:

$$n_{i \cdot} = \sum_{j=1}^k n_{i,j} \quad (i = 1, 2, \dots, h)$$



# TABELLE DI CONTINGENZA

$X$	$w_1$	$w_2$	$\dots$	$w_j$	$\dots$	$w_k$	
$Y$							
$z_1$	$n_{11}$	$n_{12}$	$\dots$	$n_{1j}$	$\dots$	$n_{1k}$	$n_{1\cdot}$
$z_2$	$n_{21}$	$n_{22}$	$\dots$	$n_{2j}$	$\dots$	$n_{2k}$	$n_{2\cdot}$
$\vdots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$
$z_i$	$n_{i1}$	$n_{i2}$	$\dots$	$n_{ij}$	$\dots$	$n_{ik}$	$n_{i\cdot}$
$\vdots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$
$z_h$	$n_{h1}$	$n_{h2}$	$\dots$	$n_{hj}$	$\dots$	$n_{hk}$	$n_{h\cdot}$
	$n_{\cdot 1}$	$n_{\cdot 2}$	$\dots$	$n_{\cdot j}$	$\dots$	$n_{\cdot k}$	$n$



# FREQUENZE RELATIVE CONGIUNTE

---

- È anche possibile considerare le **frequenze relative** associate ad una tabella di contingenza.
- Parliamo in questo caso di **frequenze relative congiunte che misurano la proporzione di osservazioni** che appartengono simultaneamente a specifiche categorie di due variabili

# FREQUENZE RELATIVE CONGIUNTE


---

- Le **frequenze relative congiunte** sono definite come:

$$f_{ij} = \frac{n_{ij}}{n} \quad (i = 1, 2, \dots, h; j = 1, 2, \dots, k)$$

In pratica, normalizziamo il numero di osservazioni in ogni cella della tabella rispetto al totale delle osservazioni.

(E secondo voi, cosa diventa?)



# FREQUENZE RELATIVE CONGIUNTE

$X$	$w_1$	$w_2$	$\dots$	$w_j$	$\dots$	$w_k$	
$Y$	$f_{11}$	$f_{12}$	$\dots$	$f_{1j}$	$\dots$	$f_{1k}$	$f_{1\cdot}$
$z_1$	$f_{21}$	$f_{22}$	$\dots$	$f_{2j}$	$\dots$	$f_{2k}$	$f_{2\cdot}$
$\vdots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\vdots$
$z_i$	$f_{i1}$	$f_{i2}$	$\dots$	$f_{ij}$	$\dots$	$f_{ik}$	$f_{i\cdot}$
$\vdots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\vdots$
$z_h$	$f_{h1}$	$f_{h2}$	$\dots$	$f_{hj}$	$\dots$	$f_{hk}$	$f_{h\cdot}$
	$f_{\cdot 1}$	$f_{\cdot 2}$	$\dots$	$f_{\cdot j}$	$\dots$	$f_{\cdot k}$	1

$$f_{ij} = \frac{n_{ij}}{n} \quad (i = 1, 2, \dots, h; j = 1, 2, \dots, k)$$

$$f_{i\cdot} = \sum_{j=1}^k f_{ij} = \sum_{j=1}^k \frac{n_{ij}}{n} = \frac{1}{n} \sum_{j=1}^k n_{ij} = \frac{n_{i\cdot}}{n}$$

$$f_{\cdot j} = \sum_{i=1}^h f_{ij} = \sum_{i=1}^h \frac{n_{ij}}{n} = \frac{1}{n} \sum_{i=1}^h n_{ij} = \frac{n_{\cdot j}}{n}$$

# FREQUENZE RELATIVE CONGIUNTE

- Consideriamo una tabella di contingenza che riassume la relazione tra due variabili categoriali: Età (Giovane, Adulto, Anziano) e Abitudine al Fumo (Fumatore, Non Fumatore)
  - Le frequenze relative congiunte rappresentano la proporzione di persone in ciascuna combinazione di categorie (Età e Abitudine al Fumo) rispetto al totale delle osservazioni

$$P(\text{Età, Abitudine al Fumo}) = \frac{\text{Frequenza Assoluta}}{\text{Totale}}$$

	Fumatore	Non Fumatore	Totale
Giovane	15	35	50
Adulto	30	20	50
Anziano	5	20	25
Totale	50	75	125



	Fumatore	Non Fumatore	Totale
Giovane	$\frac{15}{125} = 0.12$	$\frac{35}{125} = 0.28$	0.40
Adulto	$\frac{30}{125} = 0.24$	$\frac{20}{125} = 0.16$	0.40
Anziano	$\frac{5}{125} = 0.04$	$\frac{20}{125} = 0.12$	0.20
Totale	0.40	0.60	1

In questo esempio:

- Giovani fumatori** costituiscono il 12% della popolazione totale;
- Giovani non fumatori** sono il 28% della popolazione totale
- Adulti fumatori** sono il 24%, mentre **adulti non fumatori** sono il 16%, e così via

# FREQUENZE RELATIVE MARGINALI

- Le **frequenze relative marginali** rappresentano la distribuzione di una singola variabile senza considerare l'altra variabile
  - Vengono calcolate come la **somma** delle frequenze relative congiunte per ciascuna categoria di una variabile, indipendentemente dalle categorie dell'altra variabile
- Le **frequenze relative marginali di  $X$**  sono invece indicate come:

$$f_{i,\cdot} = \sum_{j=1}^k f_{ij} = \sum_{j=1}^k \frac{n_{ij}}{n} = \frac{1}{n} \sum_{j=1}^k n_{ij} = \frac{n_{i\cdot}}{n}$$

- mentre quelle di  $Y$  sono definite come:

$$f_{\cdot,j} = \sum_{i=1}^h f_{ij} = \sum_{i=1}^h \frac{n_{ij}}{n} = \frac{1}{n} \sum_{i=1}^h n_{ij} = \frac{n_{\cdot j}}{n}$$

$X$	$Y$	$w_1$	$w_2$	$\dots$	$w_j$	$\dots$	$w_k$	
$z_1$		$n_{11}$	$n_{12}$	$\dots$	$n_{1j}$	$\dots$	$n_{1k}$	$n_{1\cdot}$
$z_2$		$n_{21}$	$n_{22}$	$\dots$	$n_{2j}$	$\dots$	$n_{2k}$	$n_{2\cdot}$
$\vdots$		$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\vdots$
$z_i$		$n_{i1}$	$n_{i2}$	$\dots$	$n_{ij}$	$\dots$	$n_{ik}$	$n_{i\cdot}$
$\vdots$		$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\vdots$
$z_h$		$n_{h1}$	$n_{h2}$	$\dots$	$n_{hj}$	$\dots$	$n_{hk}$	$n_{h\cdot}$
		$n_{\cdot 1}$	$n_{\cdot 2}$	$\dots$	$n_{\cdot j}$	$\dots$	$n_{\cdot k}$	$n$

TABELLA DI CONTINGENZA

# FREQUENZE RELATIVE MARGINALI

	Fumatore	Non Fumatore	Totale
Giovane	15	35	50
Adulto	30	20	50
Anziano	5	20	25
Totale	50	75	125



	Fumatore	Non Fumatore	Totale
Giovane	$\frac{15}{125} = 0.12$	$\frac{35}{125} = 0.28$	0.40
Adulto	$\frac{30}{125} = 0.24$	$\frac{20}{125} = 0.16$	0.40
Anziano	$\frac{5}{125} = 0.04$	$\frac{20}{125} = 0.12$	0.20
Totale	0.40	0.60	1

	Totale	Frequenza Relativa Marginale
Giovane	50	$\frac{50}{125} = 0.40$
Adulto	50	$\frac{50}{125} = 0.40$
Anziano	25	$\frac{25}{125} = 0.20$
Totale	125	1



	Totale	Frequenza Relativa Marginale
Fumatore	50	$\frac{50}{125} = 0.40$
Non Fumatore	75	$\frac{75}{125} = 0.60$
Totale	125	1

# TABELLE DI CONTINGENZA

---

- In R per determinare le distribuzioni di frequenza bivariate il comando da utilizzare è sempre `table()`
  - Ad esempio, per un campione di 15 individui, consideriamo una tabella di contingenza supponendo che X individua il colore dei capelli (biondi, castani, neri, rossi) e Y il tipo di capelli (lisci, ondulati, ricci):

```
> colore<-c("biondi","castani","neri","rossi","biondi","castani",
+ "neri","castani","biondi","biondi","castani","castani",
+ "castani","neri","rossi")
>
> tipo<-c("lisci","lisci","lisci","lisci","ondulati","ondulati",
+ "ondulati","ondulati","ondulati","ondulati","ondulati",
+ "ricci","ricci","lisci","ricci")
>
> table(colore, tipo)
      tipo
colore   lisci ondulati ricci
  biondi     1      3    0
  castani    1      3    2
  neri       2      1    0
  rossi      1      0    1
```

# TABELLE DI CONTINGENZA

---

- Dopo aver creato la tabella della distribuzione di frequenza congiunta nomeTable utilizziamo le operazioni di slicing
  - Per estrarre la riga  $i$ -esima basta utilizzare il comando nomeTable[i, ]
  - Per estrarre la colonna  $j$ -esima basta utilizzare il comando nomeTable[, j].
- Ad esempio, riferendoci all'esempio precedente, estraiamo la seconda riga e la terza colonna della tabella di contingenza:

```
> capelli<-table(colore ,tipo)
>
> capelli [2,] # seconda riga della tabella
  lisci ondulati    ricci
    1         3         2
>
> capelli [,3] # terza colonna della tabella
  biondi castani    neri    rossi
    0         2         0         1
```

# TABELLE DI CONTINGENZA

---

- I comandi `margin.table(nomeTable, 1)` e `margin.table(nomeTable, 2)` permettono rispettivamente di ottenere la distribuzione di frequenza marginale di  $X$  e la distribuzione di frequenza marginale di  $Y$ 
  - Riferendosi all'esempio precedente calcoliamo le due distribuzioni di frequenza marginali:

```
> capelli<-table(colore, tipo)
>
> margin.table(capelli ,1) # distribuzione marginale del colore dei
  capelli
colore
biondi castani     neri    rossi
      4       6       3       2
>
> margin.table(capelli ,2) # distribuzione marginale del tipo dei
  capelli
tipo
lisci ondulati     ricci
      5       7       3
```

# GRAFICI DI FREQUENZA E CONTINGENZA

## Tabelle di contingenza

- In R, per calcolare la distribuzione delle frequenze relative congiunte si può utilizzare il comando **prop.table(nomeTabella)**
- Da questa si possono ricavare le distribuzioni delle frequenze relative marginali utilizzando **margin.table()**

```
> prop.table(capelli) # frequenze relative congiunte  
  tipo  
colore      lisci    ondulati     ricci  
biondi  0.06666667  0.20000000  0.00000000  
castani  0.06666667  0.20000000  0.13333333  
neri    0.13333333  0.06666667  0.00000000  
rossi   0.06666667  0.00000000  0.06666667  
>  
> freqCapelli <- prop.table(capelli)  
>  
> margin.table(freqCapelli, 1) # distribuzione delle frequenze  
  relative marginali del colore dei capelli  
colore  
biondi   castani    neri    rossi  
0.2666667 0.4000000  0.2000000  0.1333333  
>  
> margin.table(freqCapelli, 2) # distribuzione delle frequenze  
  relative marginali del tipo di capelli  
tipo  
lisci    ondulati     ricci  
0.3333333 0.4666667  0.2000000
```

# GRAFICI DI FREQUENZA E CONTINGENZA

## Tabelle di contingenza

- Conoscendo la distribuzione delle frequenze relative congiunte e la distribuzione delle frequenze relative marginali è possibile calcolare la **distribuzione delle frequenze relative di Y condizionata dalle modalità assunte da X**, così definita:

$$f(j|i) = \frac{f_{ij}}{f_{\cdot i}} = \frac{n_{ij}}{n_{\cdot i}} \quad (i = 1, 2, \dots, h; j = 1, 2, \dots, k)$$

- Allo stesso modo, è possibile calcolare **distribuzione delle frequenze relative di X condizionata dalle modalità assunte da Y**:

$$f(i|j) = \frac{f_{ij}}{f_{\cdot j}} = \frac{n_{ij}}{n_{\cdot j}} \quad (i = 1, 2, \dots, h; j = 1, 2, \dots, k)$$

- Una proprietà fondamentale delle frequenze relative condizionate è la seguente:

$$\sum_{j=1}^k f(j|i) = 1 \quad (i = 1, 2, \dots, h), \quad \sum_{i=1}^h f(i|j) = 1 \quad (j = 1, 2, \dots, k).$$

# GRAFICI DI FREQUENZA E CONTINGENZA

- Il comando `prop.table(nomeTabella, 1)` permette invece di ottenere la distribuzione delle **frequenze relative di Y condizionata dalle modalità assunte da X**, mentre il comando `prop.table(nomeTabella, 2)` permette di ricavare la distribuzione delle frequenze relative di X condizionata dalle modalità assunte da Y.
- Riferendosi all'esempio precedente si ha:

```
> prop.table(capelli, 1) # distribuzione delle frequenze relative  
    condizionate  $f(j/i)$   
    tipo  
colore      lisci  ondulati   ricci  
  biondi  0.2500000 0.7500000 0.0000000  
  castani  0.1666667 0.5000000 0.3333333  
  neri    0.6666667 0.3333333 0.0000000  
  rossi   0.5000000 0.0000000 0.5000000  
>  
> prop.table(capelli, 2) # distribuzione delle frequenze relative  
    condizionate  $f(i/j)$   
    tipo  
colore      lisci  ondulati   ricci  
  biondi  0.2000000 0.4285714 0.0000000  
  castani 0.2000000 0.4285714 0.6666667  
  neri    0.4000000 0.1428571 0.0000000  
  rossi   0.2000000 0.0000000 0.3333333
```


# GRAFICI DI FREQUENZA E CONTINGENZA

---

## Grafici per tabelle di contingenza

- Sia  $X$  una variabile di tipo qualitativo e indichiamo con  $z_1, z_2, \dots, z_h$  le modalità distinte da essa assunte e sia  $Y$  un'altra variabile e indichiamo con  $w_1, w_2, \dots, w_k$  le modalità distinte da essa assunte.
- Considerando un campione  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$  costituito da  $n$  osservazioni di  $(X, Y)$ , costruiamo la tabella di contingenza contenente nella posizione  $(i, j)$  la frequenza congiunta  $n_{ij}$ , che rappresenta il numero di volte in cui una particolare coppia di valori  $(z_i, w_j)$  si presenta nel campione.
- Le tabelle di contingenza possono essere rappresentate graficamente in vari modi.


- Una tabella grafico con rettangoli è
- Il rettangolo posizione n relativo dell congiunta.
- In R, se si as rettangoli d plot(Z).
- Ad esempio un campion



# GRAFICI DI FREQUENZA E CONTINGENZA

## Grafici per tabelle di contingenza

```
> colore<-c("biondi","castani","neri","rossi","biondi","castani",
+ "neri","castani","biondi","biondi","castani","castani",
+ "castani","neri","rossi")
>
> tipo<-c("lisci","lisci","lisci","lisci","ondulati","ondulati",
+ "ondulati","ondulati","ondulati","ondulati",
+ "ricci","ricci","lisci","ricci")
>
> table(colore, tipo)
    tipo
colore   lisci ondulati ricci
  biondi     1      3     0
  castani    1      3     2
  neri       2      1     0
  rossi      1      0     1
> capelli<-table(colore, tipo)
>
> plot(capelli, col="orange")
```




- Da notare come siano presenti solo 9 rettangoli pieni e 3 vuoti corrispondenti alle coppie la cui frequenza è nulla

# GRAFICI DI FREQUENZA E CONTINGENZA

- La tabella di contingenza può essere rappresentata mediante un **grafico a barre sovrapposte (Stacked)**.
- Il numero di barre è pari al numero delle modalità delle colonne della tabella di contingenza
  - Inoltre, all'interno di ciascuna barra sono rappresentate una sopra l'altra in altezza **le frequenze di ciascuna modalità** delle righe della tabella di contingenza.
- Nel seguente codice, invece, sono state invertite le righe e le colonne della tabella di contingenza. Si noti come sull'asse delle ordinate siano indicate le frequenza assolute congiunte


```
> capelli<-table(colore ,tipo)
> barplot(capelli ,main="Frequenza assoluta congiunta",
+ legend=c("biondi","castani","neri","rossi"),
+ col=c("yellow","brown","black","red"))
```



# GRAFICI DI FREQUENZA E CONTINGENZA

- È preferibile rappresentare la tabella di contingenza mediante un **grafico a barre sovrapposte (Stacked)**.
- Il numero di barre è pari al numero delle modalità delle colonne della tabella di contingenza
  - Inoltre, all'interno di ciascuna barra sono rappresentate una sopra l'altra in altezza **le frequenze di ciascuna modalità** delle righe della tabella di contingenza.
- Nel seguente codice, invece, sono state invertite le righe e le colonne della tabella di contingenza. Si noti come sull'asse delle ordinate siano indicate le frequenza assolute congiunte

```
> capelliNew <- table(tipo,colore)
> barplot(capelliNew,main="Frequenza assoluta congiunta",
+ legend=c("lisci","ondulati","ricci"),
+ col=c("red","green","blue"))
```




# GRAFICI DI FREQUENZA E CONTINGENZA

## Grafici per tabelle di contingenza

- **Grafici per le frequenze assolute marginali:** Per ottenere un grafico a barre della distribuzione marginale relativa al colore dei capelli basta utilizzare il comando:

```
> plot(margin.table(capelli ,1),  
+ main="Frequenza assoluta marginale del colore dei capelli",  
+ col=1:4)
```




# GRAFICI DI FREQUENZA E CONTINGENZA

## Grafici per tabelle di contingenza

- **Grafici per le frequenze assolute marginali:** Per ottenere un grafico a barre della distribuzione marginale relativa al colore dei capelli basta utilizzare il comando:

```
> plot(margin.table(capelli ,1),  
+ main="Frequenza assoluta marginale del colore dei capelli",  
+ col=1:4)  
  
• Oppure:  
  
> barplot(margin.table(capelli ,1),  
+ main="Frequenza assoluta marginale del colore dei capelli",
```




# GRAFICI DI FREQUENZA E CONTINGENZA

## Grafici per tabelle di contingenza

- Analogamente, per il grafico della **distribuzione marginale** relativa al tipo di capelli basta utilizzare il comando:

```
> plot(margin.table(capelli ,2),  
+ main="Frequenza assoluta marginale del tipo dei capelli",  
+ col=1:3)
```



# GRAFICI DI FREQUENZA E CONTINGENZA


## Grafici per tabelle di contingenza

- Analogamente, per il grafico della **distribuzione marginale** relativa al tipo di capelli basta utilizzare il comando:

```
> plot(margin.table(capelli ,2),  
+ main="Frequenza assoluta marginale del tipo dei capelli",  
+ col=1:3)
```

- Oppure, per avere un grafico a barre:

```
> barplot(margin.table(capelli ,2),  
+ main="Frequenza assoluta marginale del tipo di capelli",  
+ col=1:3)
```



# GRAFICI DI FREQUENZA E CONTINGENZA



- **Grafici per le frequenze relative congiunte:** Consideriamo ora le distribuzioni le frequenze relative e generiamo un grafico a barre stacked:

```
> capelli<-table(colore, tipo)
> freqCapelli<-prop.table(capelli)
> barplot(freqCapelli, main="Frequenza relativa congiunta",
+ legend=c("biondi", "castani", "neri", "rossi"),
+ col=c("yellow", "brown", "black", "red"))
```

- Analogamente, con il seguente codice otteniamo un altro barplot equivalente

```
> capelliNew<-table(tipo, colore)
> freqCapelliNew<-prop.table(capelliNew)
> barplot(freqCapelliNew, main="Frequenza relativa congiunta",
+ legend=c("lisci", "ondulati", "ricci"),
+ col=c("red", "green", "blue"))
```

- Si noti che in entrambi i grafici sull'asse delle ordinate sono indicate le frequenze relative congiunte



# DOMANDE?

