

# STATISTICA E ANALISI DEI DATI

Seconda Parte


Dott. Stefano Cirillo

Dott. Luigi Di Biasi

a.a. 2025-2026

# INTRODUZIONE

- L'indagine statistica è sempre effettuata su un insieme di entità (individui, oggetti,...) su cui si manifesta un fenomeno che si studia
- L'insieme di entità è detto **popolazione** o **universo** e può essere costituito da:
  - un numero finito di unità: **popolazione finita**
    - Si osserva la totalità delle entità della popolazione oppure un sottoinsieme di questa, detto **campione** estratto, per studiare le caratteristiche di una popolazione finita
  - un numero non finito di unità: **popolazione illimitata**
    - Data la dimensione, può invece essere studiata soltanto tramite un **campione** estratto
- **Spazio campionario ( $\Omega$ )**: insieme di tutti i possibili campioni
  - Può essere discreto o continuo a seconda della natura (discreta o continua) della variabile  $X$



# INFERENZA STATISTICA

---

- L'**inferenza statistica** ha lo scopo di estendere le misure ricavate dall'esame di un campione all'intera popolazione da cui il campione è stato estratto

## 1. Problema dell'inferenza statistica:

- Si considera una popolazione descritta da una **variabile aleatoria**  $X$ , che rappresenta un fenomeno osservabile (come l'altezza delle persone, il risultato di un esperimento, ecc.)
- La distribuzione di  $X$  è nota nella forma, ma contiene un parametro  $\vartheta$  (ad esempio, la media o la deviazione standard) che non è noto e che desideriamo stimare.

## 2. Spazio dei Parametri:


- Il parametro sconosciuto  $\vartheta$  appartiene a uno **spazio dei parametri**  $\Theta$ , che rappresenta l'insieme di tutti i valori possibili per  $\vartheta$ 
  - Ad esempio, se  $\vartheta$  è la probabilità di successo in un processo binomiale,  $\Theta$  sarà l'intervallo  $[0, 1]$
- Il valore reale di  $\vartheta$  **non è noto**, e il nostro obiettivo è stimarla o fare inferenze su di esso.
- Si desidera studiare una popolazione descritta da una **variabile aleatoria osservabile**  $X$  la cui funzione di distribuzione ha una forma nota ma contiene un parametro  $\vartheta \in \Theta$  (spazio dei parametri) non noto



# INFERENZA STATISTICA

## 3. Osservabilità:


- **Osservabile**: si possono osservare i valori assunti dalla variabile aleatoria  $X$  (ad esempio, eseguendo un esperimento casuale) e quindi il parametro non noto è presente soltanto nella **legge di probabilità** (funzione di distribuzione, funzione di probabilità, ...)
- Possiamo osservare i valori assunti dalla variabile aleatoria  $X$ , ad esempio **raccogliendo dati** attraverso un esperimento o un campionamento dalla popolazione
  - Tuttavia, il parametro  $\vartheta$  non è direttamente osservabile; è presente solo nella forma della distribuzione di probabilità di  $X$  (es., la funzione di densità o la funzione di probabilità di  $X$ ), ed è questa relazione che vogliamo sfruttare per stimare  $\vartheta$



# INFERENZA STATISTICA

## 4. Distribuzione Completamente Specificata:

- Se il valore di  $\vartheta$  fosse noto, la distribuzione di probabilità di  $X$  sarebbe completamente determinata, e potremmo descrivere esattamente la variabilità di  $X$  all'interno della popolazione.
- Tuttavia, poiché  $\vartheta$  è **sconosciuto**, per ottenere informazioni sul parametro non noto  $\vartheta$  della popolazione, si può fare uso dell'inferenza statistica considerando un **campione**  $(x_1, x_2, \dots, x_n)$  estratto dalla popolazione e effettuando su tale campione delle opportune **misure**




# STIMA DEI PARAMETRI

- L'inferenza statistica si basa su **due metodi fondamentali di indagine:**


**1. Stima dei parametri:** sulla base del campione si assegna al parametro di interesse ( $\vartheta$ )

un valore (**stima puntuale**) o un insieme di valori (**stima per intervallo**)

- **Scopo:** Fornire una migliore approssimazione possibile del parametro sconosciuto  $\vartheta$  che caratterizza la popolazione



**Stima puntuale**



**Stima per intervallo (di confidenza)**

- Esempio: sulla base di un campione di soggetti si stima che l'altezza media degli italiani è pari a 175,36cm o è compresa nell'intervallo (173; 178)

# VERIFICA DELLE IPOTESI


**2. Verifica delle ipotesi:** si formula un'ipotesi, o congettura, sul parametro di interesse ( $\vartheta$ ) e si verifica, sulla base del campione, se tale ipotesi è o meno accettabile (o plausibile)

- **Scopo:** Determinare, sulla base di un campione, se una certa affermazione (ipotesi) riguardo al parametro sconosciuto può essere ritenuta **plausibile**

- **Problema della verifica delle ipotesi** consiste allora nel suddividere, mediante opportuni criteri, l'insieme dei possibili campioni in due sottoinsiemi, un sottoinsieme A di accettazione dell'ipotesi nulla e un sottoinsieme R di rifiuto dell'ipotesi nulla
- Lo spazio dei parametri  $\Theta$  si suddivide in due sottoinsiemi disgiunti  $\Theta_0$  e  $\Theta_1$  tali che  $\Theta = \Theta_1 \cup \Theta_2$


- L'ipotesi  $H_0$  soggetta a verifica su  $\vartheta$  consiste nell'affermare che  $\vartheta \in \Theta_0$  ed è detta ipotesi nulla, mentre nell'ipotesi alternativa  $H_1$  si assume invece che  $\vartheta \in \Theta_1$

- Esempio: si formula l'ipotesi che l'altezza media degli italiani sia pari a 175cm e sulla base di 10 soggetti estratti casualmente si decide se tale ipotesi è plausibile o meno



# VARIABILI ALEATORIE (o VARIABILI CASUALI)

- Una **variabile aleatoria**  $X$  è una funzione che associa a ogni elemento  $E$  dello **spazio campionario**  $\Omega$  un unico numero reale possibile che è l'**esito** di un esperimento casuale
- Formalmente, una variabile aleatoria può essere definita come una funzione  $X$  che mappa ogni elemento  $E$  dello spazio degli esiti  $\Omega$  (lo spazio campionario) in un numero reale  $X_E$
- Esempi:
  - Somma dei punteggi nel lancio di due dadi
  - Numero di pezzi difettosi in un lotto
  - Variazione giornaliera nel rendimento di un titolo
  - Numero di prodotti di un certo tipo venduti giornalmente in un particolare punto vendita




# VARIABILI ALEATORIE (o VARIABILI CASUALI)

- Una variabile aleatoria può essere classificata come:
  - **Discreta**: può assumere un insieme discreto (finito o numerabile) di numeri reali
  - **Continua**: può assumere tutti i valori compresi in un intervallo reale

$\Omega$  Discreto → Variabile Aleatoria Discreta

$\Omega$  Continuo → Variabile Aleatoria Continua

- Le variabili aleatorie sono descritte dalle loro **funzioni di distribuzione**, che specificano la probabilità di ciascun possibile valore (nel caso discreto) o la probabilità che la variabile assuma valori entro un certo intervallo (nel caso continuo)



# VARIABILE ALEATORIA DISCRETA


- Una variabile aleatoria **discreta**  $X$  assume un **numero finito** o al più numerabile di valori  $(x_1, x_2, \dots, x_n)$
- La **funzione di probabilità** di una variabile aleatoria discreta  $X$  è una funzione che associa a ciascun valore possibile di  $X$  la probabilità che  $X$  assuma quel valore
  - Se denotiamo con  $p(x_i)$  la funzione di probabilità di  $X$ , abbiamo che:

$$p(x_i) = P(X = x_i)$$

dove  $P(X = x_i)$  è la probabilità che la variabile aleatoria  $X$  assuma il valore  $x_i$

- Quindi si ha che ad ogni valore  $x_i$  è associata la corrispondente probabilità  $P(X = x_i)$ , cioè
$$(p_X(x_1), p_X(x_2), \dots, p_X(x_n))$$
- La **funzione di probabilità** deve verificare le due **proprietà**:
  - $P(x_i) \geq 0, \forall i$
  - La somma delle probabilità per tutti i valori possibili è:  $\sum_i P(X_i) = 1$


$x_i$	$x_1$	$x_2$	$x_3$	...	$x_n$
$P(X = x_i)$	$p(x_1)$	$p(x_2)$	$p(x_3)$	...	$p(x_n)$




# FUNZIONE DI PROBABILITÀ (ESEMPIO)

- Esempio:

- Supponiamo di eseguire tre lanci successivi di una moneta e di voler rappresentare la distribuzione di probabilità della variabile
- $X$  = numero di teste che si possono presentare
- L'insieme universo  $U$  è costituito da 8 eventi:  
 $U = \{\text{TTT}, \text{TTC}, \text{TCT}, \text{TCC}, \text{CTT}, \text{CTC}, \text{CCT}, \text{CCC}\}$
- come si vede, le cose da fare sono poche,  
bisogna solo determinare:
  - Quali valori può assumere la variabile
  - Con quale probabilità può assumere tali valori



valori $x_i$	probabilità $p_i$
3	$\frac{1}{8}$
2	$\frac{3}{8}$
1	$\frac{3}{8}$
0	$\frac{1}{8}$



# FUNZIONE DI PROBABILITÀ (ESEMPIO)

---

- Esempio:

- In un sistema con una cache che memorizza temporaneamente i dati più richiesti, possiamo definire una **variabile aleatoria discreta**  $X$  che rappresenta l'accesso a specifici dati
- Supponiamo che abbiamo un insieme di dati  $x_1, x_2, \dots, x_n$  e che ogni dato abbia una probabilità diversa di essere richiesto, basata su dati storici di accesso
- La funzione di probabilità  $P(X = x_i)$  rappresenta la probabilità che il dato  $x_i$  sia richiesto dal sistema. Ad esempio:
  - Dato  $x_1$ : 30% delle richieste
  - Dato  $x_2$ : 25% delle richieste
  - Dato  $x_3$ : 20% delle richieste
  - Dato  $x_4$ : 15% delle richieste
  - Dato  $x_5$ : 10% delle richieste

# FUNZIONE DI PROBABILITÀ (ESEMPIO)

- Esempio:

- In un sistema con una cache che memorizza temporaneamente i dati più richiesti, possiamo definire una **variabile aleatoria discreta**  $X$  che rappresenta l'accesso a specifici dati
- Supponiamo che abbiamo un insieme di dati  $x_1, x_2, \dots, x_n$  e che ogni dato abbia una **probabilità diversa di essere richiesto**, basata su dati storici di accesso
- La funzione di probabilità  $P(X = x_i)$  rappresenta la probabilità che il dato  $x_i$  sia richiesto dal sistema. Ad esempio:

- Dato  $x_1$ : 30% delle richieste
- Dato  $x_2$ : 25% delle richieste
- Dato  $x_3$ : 20% delle richieste
- Dato  $x_4$ : 15% delle richieste
- Dato  $x_5$ : 10% delle richieste

Questo insieme di dati è racchiuso da un'elica blu.

Questa funzione di probabilità potrebbe essere utilizzata per **ottimizzare le operazioni di cache**:

- Allocando maggiore spazio a  $x_1$  e  $x_2$ , che hanno le probabilità più alte
- Aggiornando o rimpiazzando i dati nella cache con minore probabilità, come  $x_5$

# FUNZIONE DI DISTRIBUZIONE

- La **funzione di distribuzione** (o **funzione di distribuzione cumulativa (FDC)**)  $F(X)$  di una variabile aleatoria discreta  $X$  è una funzione che, dato un valore  $x_i$ , restituisce la probabilità che  $X$  assuma il un valore **minore o uguale** a  $x_i$

$$F(x_i) = P(X \leq x_i) = \sum_i p(x_i)$$


$x_i$	$x_1$	$x_2$	$x_3$	...	$x_n$
$P(X = x_i)$	$p(x_1)$	$p(x_2)$	$p(x_3)$	...	$p(x_n)$
$F(x_i)$	$p(x_1)$	$p(x_1) + p(x_2)$	$p(x_1) + p(x_2) + p(x_3)$	...	1

- Monotona non decrescente:**
  - $F(x)$  è una funzione che non diminuisce mai al crescere di  $x$ , cioè se  $x_1 < x_2$ , allora  $F(x_1) \leq F(x_2)$
- Salti:**
  - Per una variabile aleatoria discreta, la funzione di distribuzione ha "salti" nei punti in cui la variabile può assumere valori specifici.

# FUNZIONE DI DISTRIBUZIONE (ESEMPIO)

- Esempio: Quando si lancia un dado, tutte e 6 le facce hanno la stessa probabilità di presentarsi

$x_i$	1	2	3	4	5	6
$P(X = x_i)$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$



- La funzione di distribuzione è pertanto una diretta conseguenza della distribuzione di probabilità

# FUNZIONE DI DISTRIBUZIONE (ESEMPIO)

- Esempio: Supponiamo di monitorare i tempi di risposta di un server, misurati in secondi, per un campione di richieste
  - Definiamo una variabile aleatoria discreta  $X$  che rappresenta il **tempo di risposta** del server, e registriamo i seguenti tempi di risposta:
    - $X = 1$ : 10% delle richieste sono servite entro 1 secondo
    - $X = 2$ : 30% delle richieste sono servite entro 2 secondi
    - $X = 3$ : 50% delle richieste sono servite entro 3 secondi
    - $X = 4$ : 10% delle richieste sono servite entro 4 secondi
- La funzione di distribuzione è pertanto una diretta conseguenza della distribuzione di probabilità

$x_i$	1	2	3	4
$P(X = x_i)$	0,1	0,3	0,5	0,1
$F(x_i)$	0,1	0,4	0,9	1

C'è una probabilità del 40% che il tempo di risposta sia al massimo 2 secondi

C'è una probabilità del 90% che il tempo di risposta sia al massimo 3 secondi

# VALORE ATTESO

---

- Supponiamo di avere una variabile aleatoria discreta  $X$  assume un numero finito o al più numerabile di valori  $(x_1, x_2, \dots, x_n)$  che associa ad ognuno dei valori  $x_i$  la corrispondente probabilità  $P(X = x_i)$ , cioè  $(p_X(x_1), p_X(x_2), \dots, p_X(x_n))$
- Chiamiamo **valore atteso** o **valor medio** o **speranza matematica** di una variabile aleatoria discreta  $X$  la sommatoria dei prodotti tra  $x_i$  e la rispettiva probabilità  $p_X(x_i)$ :


$$E(X) = \sum_{i=1}^n x_i * P(X = x_i) = \sum_{i=1}^n x_i * p_X(x_i)$$

- Il valore atteso è una misura della sua **media ponderata** dei valori possibili, tenendo conto delle probabilità con cui ciascun valore si verifica
- In altre parole, rappresenta il valore medio (o **tendenza centrale dei dati**) che ci si aspetta di ottenere quando la variabile aleatoria viene **ripetutamente** misurata o campionata un gran numero di volte

# VALORE ATTESO

- Esempio: Supponiamo che la variabile aleatoria  $X$  indichi la somma dei punti ottenuti con il lancio di due dadi. Calcolare il punteggio totale atteso

$$\Omega = \{(i, j) \mid i, j = 1, 2, 3, 4, 5, 6\} = \left\{ (1, 1), (1, 2), (1, 3), (1, 4), (1, 5), (1, 6), \right. \\ \left. (2, 1), (2, 2), (2, 3), (2, 4), (2, 5), (2, 6), \right. \\ \left. (3, 1), (3, 2), (3, 3), (3, 4), (3, 5), (3, 6), \right. \\ \left. (4, 1), (4, 2), (4, 3), (4, 4), (4, 5), (4, 6), \right. \\ \left. (5, 1), (5, 2), (5, 3), (5, 4), (5, 5), (5, 6), \right. \\ \left. (6, 1), (6, 2), (6, 3), (6, 4), (6, 5), (6, 6) \right\}$$



# VALORE ATTESO

- Esempio: Supponiamo che la variabile aleatoria  $X$  indichi la somma dei punti ottenuti con il lancio di due dadi. Calcolare il punteggio totale atteso

$$\Omega = \{(i, j) \mid i, j = 1, 2, 3, 4, 5, 6\} = \left\{ (1, 1), (1, 2), (1, 3), (1, 4), (1, 5), (1, 6), \right. \\ \left. (2, 1), (2, 2), (2, 3), (2, 4), (2, 5), (2, 6), \right. \\ \left. (3, 1), (3, 2), (3, 3), (3, 4), (3, 5), (3, 6), \right. \\ \left. (4, 1), (4, 2), (4, 3), (4, 4), (4, 5), (4, 6), \right. \\ \left. (5, 1), (5, 2), (5, 3), (5, 4), (5, 5), (5, 6), \right. \\ \left. (6, 1), (6, 2), (6, 3), (6, 4), (6, 5), (6, 6) \right\}$$

$x_i$	2	3	4	5	6	7	8	9	10	11	12
$p_X(x_i)$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

$$E(X) = \sum_{i=2}^{12} x_i * p_X(x_i) = 2 * \frac{1}{36} + 3 * \frac{2}{36} + \dots + 12 * \frac{1}{36} = 7$$

# VARIANZA

- La **varianza**  $Var(X)$  è una misura di **dispersione** che indica quanto i valori di una variabile aleatoria si **discostano** dal valore atteso (media)
- Per una variabile aleatoria  $X$  con valore atteso  $E[X] = \mu$ , la varianza  $Var(X)$  è definita come il valore atteso del quadrato della differenza tra  $X$  e la sua media:


$$Var(X) = E[(X - \mu)^2]$$

- Che può essere riscritta come:

$$Var(X) = E[X^2] - (E[X])^2$$

- Chiamiamo **varianza** di una **variabile aleatoria discreta**  $X$  la sommatoria dei prodotti tra  $x_i$ , la rispettiva probabilità  $p_X(x_i)$  ed il valore atteso  $\mu$ :

$$Var(X) = \sum_{i=1}^n p_X(x_i) * (x_i - \mu)^2$$



Esempio di campioni da due popolazioni con la stessa media ma diversa varianza. La popolazione rossa ha media 100 e varianza 100 (SD=10), invece la popolazione blu ha media 100 e varianza 2500 (SD=50).

# VARIANZA

---

$$Var(X) = \sum_{i=1}^n p_X(x_i) * (x_i - \mu)^2$$

- **Interpretazione dei valori della Varianza**

- **Varianza piccola:** i valori della variabile sono **molto vicini alla media**. Questo significa che la variabile aleatoria o il dataset ha **bassa variabilità**
  - Ad esempio, se un server ha un tempo di risposta con una varianza molto bassa, significa che il tempo di risposta è piuttosto consistente e prevedibile.
- **Varianza grande:** i valori sono **ampiamente distribuiti attorno alla media** e mostrano alta variabilità
  - Ad esempio, in un sistema informatico, un tempo di risposta con elevata varianza indica che il tempo di risposta del server è molto variabile, e potrebbe non essere affidabile o prevedibile

# QUANTILI

---

- I quantili in una variabile aleatoria sono valori che suddividono la distribuzione in percentuali specifiche
- Questi valori sono utili per comprendere la posizione relativa di un dato all'interno della distribuzione
- I **quantili** di una variabile aleatoria sono ottenuti utilizzando la definizione di quantile per una **distribuzione di frequenza**

- Il quantile (percentile)  $z * 100$ -esimo di una variabile aleatoria  $X$  è definito come il più piccolo numero reale  $x$ , assunto dalla variabile aleatoria  $X$ , tale che:

$$F_X(x) = P(X \leq x) \geq z, \quad 0 \leq z \leq 1.$$

cioè la funzione di distribuzione  $F_X(x) = P(X \leq x)$  assuma valori maggiori o uguali di  $z$

- Per calcolare i **quartili** di una variabile aleatoria  $X$  basta porre:
  - $z = 0.25$  (primo quartile o 25-esimo percentile)
  - $z = 0.50$  (secondo quartile o mediana di una distribuzione di frequenza o 50-esimo percentile)
  - $z = 0.75$  (terzo quartile o 75-esimo percentile)

# VARIABILI ALEATORIE DISCRETE




---

- R mette a disposizione per ciascuna delle principali variabili aleatorie discrete:
  - la funzione di probabilità;
  - la funzione di distribuzione;
  - la funzione per calcolare i quantili;
  - la funzione che simula la variabile aleatoria mediante la **generazione** di sequenze di numeri pseudocasuali
- I nomi delle funzioni iniziano con una lettera dell'alfabeto che indica il tipo di funzione a cui fa riferimento:
  - **d()** calcola la funzione di probabilità di una variabile aleatoria in uno specifico punto o in un insieme di punti (**density mass**);
  - **p()** calcola la funzione di distribuzione di una variabile aleatoria in uno specifico punto o in un insieme di punti (**probability distribution**);
  - **q()** calcola i **quantili**;
  - **r()** simula una variabile aleatoria generando una sequenza di numeri pseudocasuali.

# VARIABILI ALEATORIE DISCRETE

- Nelle prossime lezioni discuteremo delle seguenti distribuzioni discrete:

- Distribuzione di Bernoulli;
- Distribuzione binomiale;
- Distribuzione geometrica;
- Distribuzione geometrica modificata;
- Distribuzione binomiale negativa;
- Distribuzione binomiale negativa modificata;
- Distribuzione di Poisson;
- Distribuzione ipergeometrica.



# STATISTICA E ANALISI DEI DATI

Distribuzione di Bernoulli



# DISTRIBUZIONE DI BERNOULLI

---

- Una prova di Bernoulli è un esperimento casuale caratterizzato da due soli possibili risultati, interpretabili l'uno come **successo** e l'altro come **insuccesso**
- Si verificano rispettivamente con probabilità  $p$  e  $1 - p$ , con  $0 < p < 1$
- La variabile aleatoria  $X$  che descrive il risultato di una prova di Bernoulli assume soltanto due valori:
  - 1 (indicante il successo) con probabilità  $p$
  - 0 (indicante l'insuccesso) con probabilità  $1 - p$ .
- Esempio: Un tipico esempio è il lancio di una moneta in cui la probabilità di ottenere testa è  $p$ 
  - Se codifichiamo testa con 1 e croce con 0, il risultato del lancio della moneta può essere descritto da una variabile aleatoria di Bernoulli con parametro  $p$



# DISTRIBUZIONE DI BERNOULLI

---

- La distribuzione di Bernoulli prende il nome da un matematico svizzero Jacob Bernoulli (1654–1705) che scoprì non solo tale distribuzione ma anche la **distribuzione binomiale**
- Con la notazione  $X \sim B(1, p)$  intenderemo che  $X$  è una variabile aleatoria avente distribuzione di Bernoulli di parametro  $p$ , che chiameremo anche **variabile di Bernoulli**
- Una variabile aleatoria  $X$  di **funzione di probabilità**:

$$p_X(x) = P(X = x_i) = \begin{cases} 1 - p & se = 0 \\ p & se x = 1 \\ 0 & altrimenti \end{cases}$$

con  $0 < p < 1$  è detta avere distribuzione di Bernoulli di parametro  $p$



# DISTRIBUZIONE DI BERNOULLI

---

- Una variabile aleatoria  $X$  di **funzione di probabilità**:

$$p_X(x) = P(X = x_i) = \begin{cases} 1 - p & se = 0 \\ p & se x = 1 \\ 0 & altrimenti \end{cases}$$

con  $0 < p < 1$  è detta avere distribuzione di Bernoulli di parametro  $p$

- Quindi una Variabile aleatoria con distribuzione di Bernoulli:

- Può assumere due valori  $X = (0,1)$  con  $x_1 = 0, x_2 = 1$
- $P(X = 1) = p$
- $P(X = 0) = 1 - p$



# DISTRIBUZIONE DI BERNOULLI

---

- Una variabile aleatoria  $X$  di **funzione di probabilità**:


$$p_X(x) = P(X = x_i) = \begin{cases} 1 - p & se = 0 \\ p & se x = 1 \\ 0 & altrimenti \end{cases}$$

con  $0 < p < 1$  è detta avere distribuzione di Bernoulli di parametro  $p$

- Quindi una Variabile aleatoria con distribuzione di Bernoulli:

- Può assumere due valori  $X = (0,1)$  con  $x_1 = 0, x_2 = 1$
- $P(X = 1) = p$
- $P(X = 0) = 1 - p$
- Il **valore atteso**

$$E[X] = \sum_{i=0}^2 x_i P(X = x_i) = 0 * (1 - p) + 1 * p = p$$



# DISTRIBUZIONE DI BERNOULLI

- Una variabile aleatoria  $X$  di **funzione di probabilità**:

$$p_X(x) = P(X = x_i) = \begin{cases} 1 - p & se = 0 \\ p & se x = 1 \\ 0 & altrimenti \end{cases}$$

con  $0 < p < 1$  è detta avere distribuzione di Bernoulli di parametro  $p$

- Quindi una Variabile aleatoria con distribuzione di Bernoulli:

- Può assumere due valori  $X = (0,1)$  con  $x_1 = 0, x_2 = 1$
- $P(X = 1) = p$
- $P(X = 0) = 1 - p$
- Il valore atteso  $E[X] = \sum_{i=0}^2 x_i P(X = x_i) = 0 * (1 - p) + 1 * p = p$
- Varianza  $\text{Var}[X] = E[X^2] - [E[X]]^2$

$$E[X^2] = \sum_{i=0}^2 x_i^2 P(X = x_i) = 0^2 * P(X = 0) + 1^2 * P(X = 1) = 0^2 * (1 - p) + 1^2 * p = p$$

$$[E[X]]^2 = p^2$$



# DISTRIBUZIONE DI BERNOULLI

- Una variabile aleatoria  $X$  di **funzione di probabilità**:

$$p_X(x) = P(X = x_i) = \begin{cases} 1 - p & se = 0 \\ p & se x = 1 \\ 0 & altrimenti \end{cases}$$

con  $0 < p < 1$  è detta avere distribuzione di Bernoulli di parametro  $p$

- Quindi una Variabile aleatoria con distribuzione di Bernoulli:

- Può assumere due valori  $X = (0,1)$  con  $x_1 = 0, x_2 = 1$
- $P(X = 1) = p$
- $P(X = 0) = 1 - p$
- Il valore atteso  $E[X] = \sum_{i=0}^2 x_i P(X = x_i) = 0 * (1 - p) + 1 * p = p$
- Varianza  $\text{Var}[X] = E[X^2] - [E[X]]^2 = p - p^2 = p(1 - p)$

$$E[X^2] = \sum_{i=0}^2 x_i^2 P(X = x_i) = 0^2 * P(X = 0) + 1^2 * P(X = 1) = 0^2 * (1 - p) + 1^2 * p = p$$

$$[E[X]]^2 = p^2$$



# DISTRIBUZIONE DI BERNOULLI

---

- Una variabile aleatoria  $X$  di **funzione di probabilità**:

$$p_X(x) = P(X = x_i) = \begin{cases} 1 - p & se = 0 \\ p & se x = 1 \\ 0 & altrimenti \end{cases}$$

con  $0 < p < 1$  è detta avere distribuzione di Bernoulli di parametro  $p$

- Per una variabile aleatoria di Bernoulli si ha:

- **Valore atteso:**  $E[X] = p$  e  $E[X^2] = p$


- **Varianza:**  $Var(X) = E[X^2] - [E[X]]^2 = p(1 - p)$

- La **funzione di distribuzione** di  $X$  è:

$$F_x(x) = \begin{cases} 0 & se x < 0 \\ 1 - p & se 0 \leq x < 1 \\ 1 & se x \geq 1 \end{cases}$$

# DISTRIBUZIONE DI BERNOULLI (ESEMPIO)

- Immaginiamo che in una fabbrica si producano pezzi con una probabilità di difettosità pari a  $p = 0.05$  (quindi c'è una probabilità del 5% che un pezzo sia difettoso)
- Definiamo la variabile casuale  $X$  come:
  - $X = 1$  se il pezzo è difettoso (successo, perché stiamo cercando difetti)
  - $X = 0$  se il pezzo non è difettoso (insuccesso)
- Poiché stiamo controllando un singolo pezzo, siamo di fronte a una singola prova ( $n = 1$ ), il che rende la distribuzione di  $X$  una distribuzione di Bernoulli  $X \sim B(1, p)$  con parametro  $p = 0.05$ 
  - Probabilità che il pezzo sia **difettoso**:  $P(X = 1) = p = 0.05$
  - Probabilità che il pezzo **NON** sia difettoso:  $P(X = 0) = 1 - p = 0.95$
  - **Valore atteso**:  $E[X] = p = 0.05$
  - **Varianza**:  $Var(X) = E[X^2] - [E[X]]^2 = p(1 - p) = 0.05 * 0.95 = 0.0475$
  - **Funzione di distribuzione**:  $F_x(x) = \begin{cases} 0 & se x < 0 \\ 1 - 0.05 & se 0 \leq x < 1 \\ 1 & se x \geq 1 \end{cases}$



# ESEMPIO CANALE DI COMUNICAZIONE

- Un sistema trasmette **bit** (0 o 1) attraverso un canale rumoroso
  - C'è una probabilità  $p = 0.002$  che il bit venga ricevuto con **errore**
  - Analizziamo **un singolo bit** trasmesso, abbiamo che possiamo definire  $X$  come:

$$X = \begin{cases} 1 & \text{se il bit viene ricevuto CON errore} \\ 0 & \text{se il bit viene ricevuto CORRETTAMENTE} \end{cases}$$

- Probabilità che il bit sia ricevuto con **errore**:  $P(X = 1) = p = 0.002$
- Probabilità che il bit sia **corretto**:  $P(X = 0) = 1 - p = 0.998$
- **Valore atteso**:  $E[X] = p = 0.05$
- **Varianza**:  $Var(X) = E[X^2] - [E[X]]^2 = p(1 - p) = 0.002 * 0.998$  oppure  $0.002 - 0.000004 = 0.001996$

# DISTRIBUZIONE DI BERNOULLI

---

- Esempi: Altri eventi che hanno una distribuzione Bernoulliana sono:
  - Il lancio di un dado, se ti interessa sapere se esce 4 o un numero diverso da 4
  - Il manifestarsi di una malattia, se ti interessa sapere se il soggetto ha o non ha quella malattia
  - La difettosità di un pezzo, se ti interessa sapere se un pezzo è difettoso oppure no
  - La nascita di un bambino, se ti interessa sapere se è maschio o femmina
  - L'estrazione ad una lotteria, in cui il biglietto può essere vincente oppure no
  - L'entrata di un cliente in un negozio, se ti interessa sapere se farà acquisti oppure no
  - La direzione da seguire, se ti interessa sapere se andare a destra oppure sinistra
  - L'invito ad uscire, se ti interessa sapere se la persona a cui l'hai chiesto risponderà “sì” oppure “no”.
  - L'offerta di cambiare operatore telefonico, che può essere accettata o rifiutata
  - Il voto ad un referendum, che può essere a favore o contro
  - ...

# STATISTICA E ANALISI DEI DATI

Distribuzione Binomiale

# DISTRIBUZIONE BINOMIALE


---

- Consideriamo l'esperimento consistente in  $n$  prove di Bernoulli indipendenti ed effettuate tutte in condizioni identiche
- Assumiamo che in ogni prova i risultati di interesse siano sintetizzabili nel verificarsi dei seguenti due eventi necessari ed incompatibili:
  - $A$ : interpretabile come successo
  - $\bar{A}$  : interpretabile come insuccesso
- con  $P(A) = p (0 < p < 1)$
- Questo esperimento si dice esperimento si dice costituito da  $n$  prove ripetute indipendenti di Bernoulli
  - **La variabile aleatoria Binomiale  $X$  rappresenta il numero di volte in cui si verifica l'evento  $A$  nelle  $n$  prove**

# DISTRIBUZIONE BINOMIALE

---

- La distribuzione binomiale è utile per modellare:
  - il numero di successi in una sequenza di lanci indipendenti di una moneta;
  - il numero di processori che sono attivi in un sistema multiprocessore;
  - il numero di computer difettosi in una spedizione;
  - il numero di articoli in un lotto che hanno determinate caratteristiche
  - ...
- Esempio:
  - Se analizziamo ad esempio il lancio di un dado regolare e prendiamo in considerazione l'evento **esce il numero 3** possiamo attribuire facilmente la probabilità associata pari  $1/6$
  - Questa probabilità resta uguale per ogni lancio, indipendentemente dal numero di lanci che effettuiamo



# DISTRIBUZIONE BINOMIALE


---

- Una variabile aleatoria  $X$  di **funzione di probabilità**:

$$p_X(x) = P(X = x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & x = 0, 1, \dots, n \\ 0 & \text{altrimenti} \end{cases}$$

con  $0 < p < 1$

- $n$  è il numero di prove
- $x$  numero di successi
- La notazione della variabile binomiale è:  $X \sim B(n, p)$  intenderemo che  $X$  è una variabile aleatoria con distribuzione binomiale di parametri  $n$  e  $p$



# DISTRIBUZIONE BINOMIALE

---

- Una variabile aleatoria  $X$  di **funzione di probabilità**:

$$P(X = x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & x = 0, 1, \dots, n \\ 0 & \text{altrimenti} \end{cases}$$

con  $0 < p < 1$

- $n$  è il numero di prove
- $x$  numero di successi
- La notazione della variabile binomiale è:  $X \sim B(n, p)$  intenderemo che  $X$  è una variabile aleatoria con distribuzione binomiale di parametri  $n$  e  $p$
- Esempio: Se vogliamo calcolare la probabilità che lanciando 5 volte un dado regolare a sei facce otteniamo esattamente 3 volte il numero 4 avremo:

$$p(3) = \binom{5}{3} * \left(\frac{1}{6}\right)^3 * \left(1 - \frac{1}{6}\right)^{5-3} = 10 * 0.0046 * 0.36 = 0.01656$$

# DISTRIBUZIONE BINOMIALE

---

- Esempio: Siamo interessati al numero di uscite di testa in 10 lanci. Qual è la probabilità di ottenere 6 uscite del lato testa?
  - Abbiamo che  $n = 10$
  - Abbiamo che  $x = 6$
- Consideriamo prima una prefissata sequenza di teste e croci

T C C T T C C T T

# DISTRIBUZIONE BINOMIALE

---

- Esempio: Siamo interessati al numero di uscite di testa in 10 lanci. Qual è la probabilità di ottenere 6 uscite del lato testa?
  - Abbiamo che  $n = 10$
  - Abbiamo che  $x = 6$
- Consideriamo prima una prefissata sequenza di teste e croci

T C C T T T C C T T

Essendo i lanci indipendenti, la probabilità cercata è data da:

$$p * (1 - p) * (1 - p) * p * p * p * (1 - p) * (1 - p) * p * p = p^6(1 - p)^{10-6}$$

# DISTRIBUZIONE BINOMIALE

- Esempio: Siamo interessati al numero di uscite di testa in 10 lanci. Qual è la probabilità di ottenere 6 uscite del lato testa?
  - Abbiamo che  $n = 10$
  - Abbiamo che  $x = 6$
- Consideriamo prima una prefissata sequenza di teste e croci

T C C T T T C C T T

Essendo i lanci indipendenti, la probabilità cercata è data da:

$$p * (1 - p) * (1 - p) * p * p * p * (1 - p) * (1 - p) * p * p = p^6(1 - p)^{10-6}$$

- Se ora volessimo calcolare la probabilità di tutte le possibili sequenze di 10 lanci in cui ci siano 6 teste dobbiamo stabilire quante sono le sequenze che presentano 6 teste e 4 croci
- Il problema è equivalente a contare tutti i modi in cui è possibile scegliere di mettere le 6 teste nei 10 lanci,

$$\text{cioè: } \binom{10}{6} = \frac{10!}{6!(10-6)!}$$

Essendo i lanci indipendenti, la probabilità cercata è data da:  $p(6) = \binom{10}{6}(p)^6(1 - p)^{10-6}$

# DA BINOMIALE A BERNOULLI

---

- Se  $n = 1$ , la funzione di probabilità:

$$\binom{n}{x} p^x (1-p)^{n-x}$$

si semplifica ottenendo:

$$P(X = x) = p^x (1-p)^{1-x}$$

- Se  $x = 0$  (insuccesso):

$$P(X = 0) = p^0 (1-p)^{1-0} = (1-p)$$

- Se  $x = 1$  (successo):

$$P(X = 1) = p^1 * (1-p)^{1-1} = p$$

# DISTRIBUZIONE BINOMIALE

---

- La **funzione di distribuzione** di  $X$  è poi immediatamente ottenibile:

$$F_X(x) = \begin{cases} 0 & x < 0 \\ \sum_{i=0}^k \binom{n}{i} p^i * (1-p)^{n-i} & k \leq x < k + 1 \ (k = 0, 1, \dots, n-1) \\ 1 & x \geq n \end{cases}$$

- Per una variabile aleatoria binomiale si ha:

$$X = X_1 + X_2 + \cdots + X_n$$

dove  $X_1, X_2, \dots, X_n$  sono variabili aleatorie di Bernoulli indipendenti ed identicamente distribuite

# VARIANZA, VALORE ATTESO, DEVIAZIONE STANDARD

- In una variabile aleatoria binomiale, il valore atteso e la varianza sono indicatori statistici importanti che forniscono informazioni sulla distribuzione della variabile
  - il **valore atteso** di una variabile aleatoria binomiale rappresenta il numero medio di **successi** attesi in  $n$  tentativi
    - **Valore atteso:**  $E(X) = np$
  - La **varianza** fornisce una misura di quanto i risultati si discostino da questo valore atteso
    - **Varianza:**  $Var(X) = np(1 - p)$
  - La **deviazione standard** è una misura della dispersione dei valori attorno alla media
    - una deviazione standard più piccola indica una maggiore coerenza dei dati intorno alla media
    - una deviazione standard più grande indica una maggiore dispersione o variabilità dei dati
  - **Deviazione standard:**  $SD(X) = \sqrt{Var(X)}$
- Se  $p = 1/2$  la funzione di probabilità binomiale è simmetrica rispetto al suo valore medio  $E(X) = n/2$

# DISTRIBUZIONE BINOMIALE (ESEMPIO)

---

- Esempio: la probabilità che il portiere del PSG pari un rigore è del 30%
  - Se durante una stagione intera la squadra subisce 10 rigori, qual è la probabilità che il portiere ne pari esattamente 4?

# DISTRIBUZIONE BINOMIALE (ESEMPIO)

- I dati che abbiamo sono:  $p = 0,30$ ,  $n = 10$ ,  $x = 4$

$$P(0) = \binom{10}{0} * 0,30^0 * (1 - 0,30)^{10-0}$$


$$P(1) = \binom{10}{1} * 0,30^1 * (1 - 0,30)^{10-1}$$

...

$$P(10) = \binom{10}{10} * 0,30^{10} * (1 - 0,30)^{10-10}$$

- Si nota subito che la funzione tocca il suo massimo nel valore medio, ovvero il 3


X	P(X)
5	0,10292
6	0,03676
7	0,009
8	0,00145
9	0,00014
10	5,9E-06



# DISTRIBUZIONE BINOMIALE (ESEMPIO)

- Esempio: la probabilità che il portiere del PSG pari un rigore è del 30%
  - Se durante una stagione intera la squadra subisce 10 rigori, qual è la probabilità che il portiere ne pari esattamente 4?
- I dati che abbiamo sono:
  - $p = 0,30$
  - $n = 10$
  - $x = 4$

$$p(4) = \binom{n}{x} p^x * (1 - p)^{n-x} \binom{10}{4} 0,30^4 * (1 - 0,30)^{10-4} = 0,20$$



# DISTRIBUZIONE BINOMIALE (ESEMPIO)

- Esempio: la probabilità che il portiere del PSG pari un rigore è del 30%
  - Se durante una stagione intera la squadra subisce 10 rigori, qual è la probabilità che il portiere ne pari esattamente 4?
- I dati che abbiamo sono:
  - $p = 0,30$
  - $n = 10$
  - $x = 4$

$$p(4) = \binom{n}{x} p^x * (1 - p)^{n-x} \binom{10}{4} 0,30^4 * (1 - 0,30)^{10-4} = 0,20$$

$$E[X] = np = 10 * 0,30 = 3$$

# DISTRIBUZIONE BINOMIALE (ESEMPIO)

- Esempio: la probabilità che il portiere del PSG pari un rigore è del 30%
  - Se durante una stagione intera la squadra subisce 10 rigori, qual è la probabilità che il portiere ne pari esattamente 4?
- I dati che abbiamo sono:
  - $p = 0,30$
  - $n = 10$
  - $x = 4$

$$p(4) = \binom{n}{x} p^x * (1 - p)^{n-x} \binom{10}{4} 0,30^4 * (1 - 0,30)^{10-4} = 0,20$$

$$E[X] = np = 10 * 0,30 = 3$$

$$Var(X) = np(1 - p) = 10 * 0,30(1 - 0,30) = 2,1$$

# DISTRIBUZIONE BINOMIALE (ESEMPIO)

- Esempio: la probabilità che il portiere del PSG pari un rigore è del 30%
  - Se durante una stagione intera la squadra subisce 10 rigori, qual è la probabilità che il portiere ne pari esattamente 4?
- I dati che abbiamo sono:
  - $p = 0,30$
  - $n = 10$
  - $x = 4$

$$p(4) = \binom{n}{x} p^x * (1 - p)^{n-x} \binom{10}{4} 0,30^4 * (1 - 0,30)^{10-4} = 0,20$$

$$E[X] = np = 10 * 0,30 = 3$$

$$Var(X) = np(1 - p) = 10 * 0,30(1 - 0,30) = 2,1$$

$$SD(X) = \sqrt{Var(X)} = 1,449$$

# DISTRIBUZIONE BINOMIALE (ESEMPIO)

- Esempio: la probabilità che il portiere del PSG pari un rigore è del 30%
  - Se durante una stagione intera la squadra subisce 10 rigori, qual è la probabilità che il portiere ne pari esattamente 4?
- I dati che abbiamo sono:
  - $p = 0,30$
  - $n = 10$
  - $x = 4$

$$p(4) = \binom{n}{x} p^x * (1 - p)^{n-x} = \binom{10}{4} 0,30^4 * (1 - 0,30)^{10-4} = 0,20$$

$$E[X] = np = 10 * 0,30 = 3$$

$$Var(X) = np(1 - p) = 10 * 0,30(1 - 0,30) = 2,1$$

$$SD(X) = \sqrt{Var(X)} = 1,449$$

- Possiamo dire che abbiamo una forte probabilità che il portiere pari dai  $3 - 1,45$  a  $3 + 1,45$

# DISTRIBUZIONE BINOMIALE (R)

- Per il calcolo in R delle probabilità binomiali si utilizza la funzione:

**dbinom(x, size, prob)**

dove

- **x** è il valore assunto (o i valori assunti) dalla variabile aleatoria binomiale;
  - **size** è il numero complessivo delle prove;
  - **prob** è la probabilità di successo in ciascuna prova
- Ad esempio, se  $n = 5$  e  $p = 0.95$  le probabilità binomiali possono essere così valutate:

```
▶ n <- 5  
p <- 0.95  
x <- 0:5  
dbinom(x, size=n, prob=p)
```

3.125000000000001e-07 · 2.968750000000001e-05 · 0.001128125 · 0.021434375 · 0.2036265625 · 0.7737809375

# DISTRIBUZIONE BINOMIALE (R)

- Creazione dei plot con diverse distribuzioni di probabilità binomiali:


```
#Creo una griglia per i grafici 2x2
par(mfrow=c(2,2))

x<-0:5
plot(x,dbinom(x,size=5,prob=0.95),xlab="x",ylab="P(X=x)",type="h",main="n=5, p=0.95")

x<-0:10
plot(x,dbinom(x,size=10,prob=0.05),xlab="x",ylab="P(X=x)",type="h",main="n=10, p=0.05")

x<-0:20
plot(x,dbinom(x,size=20,prob=0.5),xlab="x",ylab="P(X=x)",type="h",main="n=20, p=0.5")

x<-0:20
plot(x,dbinom(x,size=20,prob=0.2),xlab="x",ylab="P(X=x)",type="h",main="n=20, p=0.2")
```



# DISTRIBUZIONE BINOMIALE (R)

---

- Per il calcolo in R della funzione di distribuzione binomiale si utilizza la funzione:

**pbinom**(x, size, prob, lower.tail = TRUE)

dove

- **x** è il valore assunto (o i valori assunti) dalla variabile aleatoria binomiale;
- **size** è il numero complessivo delle prove;
- **prob** è la probabilità di successo in ciascuna prova
- **lower.tail** se tale parametro è TRUE (caso di default) calcola  $P(X \leq x)$ , mentre se tale parametro è FALSE calcola  $P(X > x)$

# DISTRIBUZIONE BINOMIALE (R)

- Ad esempio, se  $n=5$  e  $p=0.95$  la funzione di distribuzione binomiale può essere così valutata:

```
▶ n <- 5  
p <- 0.95  
x <- 0:5  
pbinom(x, size=n, prob=p)
```

3.125000000000001e-07 · 3.000000000000001e-05 · 0.001158125 · 0.0225925 · 0.2262190625 · 1

- I cui risultati sono le probabilità:

$$P(X \leq x) = \sum_{n=0}^x P(X = x) \quad x = 0, 1, \dots, 5$$

- Impostando il parametro *lower.tail = FALSE*

```
▶ n <- 5  
p <- 0.95  
x <- 0:5  
pbinom(x, size=n, prob=p, lower.tail=FALSE)
```

0.999996875 · 0.99997 · 0.998841875 · 0.9774075 · 0.7737809375 · 0

- Mostrano le probabilità:

$$P(X > x) = 1 - P(X \leq x) \quad x = 0, 1, \dots, 5$$

# DISTRIBUZIONE BINOMIALE (R)





- Creazione dei plot con diverse funzioni di distribuzione:

```
R> par(mfrow=c(2,2))
R> x<-0:5
R> plot(x,pbinom(x,size=5,prob=0.95),xlab="x",ylab=expression(P(X <=x)),ylim=c(0,1),type="s",main="n=5,p=0.95")

R> x<-0:10
R> plot(x,pbinom(x,size=10,prob=0.05),xlab="x",ylab=expression(P(X <=x)),ylim=c(0,1),type="s",main="n=10,p=0.05")

R> x<-0:20
R> plot(x,pbinom(x,size=20,prob=0.5),xlab="x",ylab=expression(P(X <=x)),ylim=c(0,1),type="s",main="n=20,p=0.5")

R> x<-0:20
R> plot(x,pbinom(x,size=20,prob=0.2),xlab="x",ylab=expression(P(X <=x)),ylim=c(0,1),type="s",main="n=20,p=0.2")
```



# ALTRI VALORI IN R


- In valutare il **valore medio**, la **varianza**, la **deviazione standard** e il **coefficiente di variazione** della distribuzione binomiale:

- Esempio: Consideriamo  $n = 20$  e probabilità  $p = 0.2$ :

- **Valore atteso**:  $E[X] = np = 20 * 0.2 = 4$
- **Varianza**:  $Var(X) = np(1 - p) = 20 * 0.2 * 0.8 = 3.2$
- **Deviazione Standard**:  $\sqrt{Var(X)} = 1.78885 \dots$
- **Coefficiente di Variazione**:  $CV(X) = \frac{\sqrt{Var(X)}}{E[X]} = 0.44721 \dots$

```
x <- 0:20  
n <- 20  
p <- 0.2  
  
M1 <- sum(x*dbinom(x,size=n, prob=p))  
M2 <- sum(x^2*dbinom(x,size=n, prob=p))  
V <- M2 - M1^2  
  
c(M1,V,sqrt(V),sqrt(V)/M1)
```

4 · 3.2 · 1.78885438199983 · 0.447213595499958



# ALTRI VALORI IN R

- Per calcolare i **Quantili** della distribuzione binomiale si utilizza la funzione:

**qbinom(z, size, prob)**

dove

- **z** è il valore assunto (o i valori assunti) dalle probabilità relative al percentile  $z \cdot 100$ -esimo;
  - **size** è il numero complessivo delle prove;
  - **prob** è la probabilità di successo in ciascuna prova
- Esempio: se  $n = 20$  e  $p = 0.2$  le seguenti linee di codice forniscono i quartili  $Q_0, Q_1, Q_2, Q_3, Q_4$ :

```
z <- c(0,0.25,0.5,0.75,1)  
qbinom(z,size=20, prob=0.2)
```

0 · 3 · 4 · 5 · 20

- Il risultato della funzione è il percentile  $z \cdot 100 - esimo$ , ossia il più piccolo numero intero  $k$  assunto dalla variabile aleatoria binomiale  $X$  tale che:

$$F_X(x) = P(X \leq k) \geq z \quad k = 0, 1, \dots, n$$

# CANALE DI COMUNICAZIONE (ESEMPIO)

- Consideriamo un canale di comunicazione binario che trasmette parole di codice di  $n$  bits
- Assumiamo che la probabilità di successo nella trasmissione di un singolo bit sia  $p$  e che la probabilità di un errore sia  $q = 1 - p$ 
  - Se assumiamo che la trasmissione di bit successivi avviene indipendentemente, siamo interessati a calcolare la probabilità di commettere al più  $n_e$  errori nella trasmissione di una parola di codice
- Denotiamo con  $N$  la variabile aleatoria che descrive il numero di errori commessi nella trasmissione di una parola di codice
  - la probabilità di commettere  $k$  errori è:

$$P(N = k) = \binom{n}{k} p^k q^{n-k} \quad k = 0, 1, \dots, n$$

- E quindi la probabilità di commettere **al più**  $n$  errori è:

$$P(N \leq n_e) = \sum_{k=0}^{n_e} \binom{n}{k} p^k q^{n-k} \quad n_e = 0, 1, \dots, n$$

# CANALE DI COMUNICAZIONE (ESEMPIO)

- Consideriamo un canale di comunicazione binario che trasmette parole di codice di  $n$  bits
- Assumiamo che la probabilità di successo nella trasmissione di un singolo bit sia  $p$  e che la probabilità di un errore sia  $q = 1 - p$ 
  - Se assumiamo che la trasmissione di bit successivi avviene indipendentemente, siamo interessati a calcolare la probabilità di commettere al più  $n_e$  errori nella trasmissione di una parola di codice
- Esempio: la probabilità di commettere al più un errore in una parola di codice di lunghezza 10 con probabilità di errore  $q = 0.1$  è calcolabile in R:

```
▶ x <- 1  
n <- 10  
p <- 0.1  
pbinom(x, n, p)
```

0.7360989291

# REGOLA DI DECISIONE A MAGGIORANZA (ESEMPIO)

- Supponiamo di effettuare  $n$  lanci ( $n = 3, 5, \dots$ ) indipendenti di una moneta
  - Supponiamo che sia  $p$  la probabilità di successo e  $1 - p$  di insuccesso in ogni singola prova
- Sia  $X$  la variabile aleatoria che descrive il **numero di successi in  $n$  prove**
  - Desideriamo calcolare la probabilità  $Q_n$  che il **numero di successi sia maggiore del numero di insuccessi** nelle  $n$  prove
    - Quando si verifica ciò?
      - si verifica se  $X > n - X$ , ossia  $X > \frac{n}{2}$  o equivalentemente  $X \geq \frac{n+1}{2}$
      - Essendo le prove indipendenti,  $X$  ha distribuzione binomiale di parametri  $n$  e  $p$ ;
      - Per  $n = 3, 5, \dots$  si ha:


$$Q_n = P\left(X > \frac{n}{2}\right) = P\left(X \geq \frac{n+1}{2}\right) = \sum_{k=\frac{n+1}{2}}^n \binom{n}{k} n^k q^{n-k}$$

# REGOLA DI DECISIONE A MAGGIORANZA (ESEMPIO)

- Si può mostrare graficamente con R che se:
  - $p > 0.5$  e  $n = 3, 5, \dots$  la probabilità  $Q_n$  è una funzione crescente in  $n$
  - $p < 0.5$  e  $n = 3, 5, \dots$  la probabilità  $Q_n$  è una funzione decrescente in  $n$
  - $p = 0.5$  risulta  $Q_n = \frac{1}{2}$  per  $n = 3, 5, \dots$
- In R, il codice per calcolare la probabilità  $Q_n$  per  $p = 0.5$  e  $n = 3, 5, \dots, 35$ :

```
► n <- seq(3,35,2)
  Qn <- pbinom(n/2, n, 0.7, lower.tail=FALSE)
  round(Qn,4)
```

0.784 · 0.8369 · 0.874 · 0.9012 · 0.9218 · 0.9376 · 0.95 · 0.9597 · 0.9674 · 0.9736 · 0.9786 · 0.9825 · 0.9857 · 0.9883 · 0.9905 ·  
0.9922 · 0.9936




# REGOLA DI DECISIONE A MAGGIORANZA (ESEMPIO)

- Si può mostrare graficamente con R che se:
  - $p > 0.5$  e  $n = 3, 5, \dots$  la probabilità  $Q_n$  è una funzione crescente in  $n$
  - $p < 0.5$  e  $n = 3, 5, \dots$  la probabilità  $Q_n$  è una funzione decrescente in  $n$
  - $p = 0.5$  risulta  $Q_n = \frac{1}{2}$  per  $n = 3, 5, \dots$
- In R, il codice per calcolare la probabilità  $Q_n$  per  $p = 0.5$  e  $n = 3, 5, \dots, 35$ :

```
► n <- seq(3,35,2)
  Qn <- pbinom(n/2, n, 0.7, lower.tail=FALSE)
  round(Qn,4)
```

0.784 · 0.8369 · 0.874 · 0.9012 · 0.9218 · 0.9376 · 0.95 · 0.9597 · 0.9674 · 0.9736 · 0.9786 · 0.9825 · 0.9857 · 0.9883 · 0.9905 ·  
0.9922 · 0.9936

```
► plot(n,Qn, xlab="Numero di prove", ylab= expression('Q'[ 'n']), ylim=c(0.7,1), type="h", main="p=0.7")
```



# REGOLA DI DECISIONE A MAGGIORANZA (ESEMPIO)

- In R, il codice per calcolare la probabilità  $Q_n$  per  $p = 0.3$  e  $n = 3, 5, \dots, 35$ :

```
n <- seq(3,35,2)
Qn <- pbinom(n/2, n, 0.3, lower.tail=FALSE)
plot(n,Qn, xlab="Numero di prove", ylab= expression('Q'[n]),ylim=c(0,0.25),type="h",main="p=0.3")
```

