

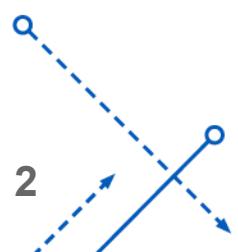
# STATISTICA E ANALISI DEI DATI

Distribuzione Poisson

# Distribuzione di Poisson

---

- La distribuzione di Poisson si utilizza è una distribuzione casuale discreta di **media e varianza identiche** che si utilizza per calcolare:
  - la probabilità che un certo evento si manifesti esattamente  $x$  volte in una **certa unità spazio-temporale**
- La distribuzione di Poisson interviene spesso nella descrizione di alcuni fenomeni coinvolgenti qualche tipo di conteggio
  - Il numero di chiamate telefoniche ricevute da un centralino in un fissato intervallo di tempo
  - Il numero di particelle radioattive emesse per unità di tempo
  - Il numero di microorganismi per unità di volume in un fluido
  - Il numero di imperfezioni per unità di lunghezza di un cavo
- Tutti questi eventi devono essere riferiti ad una certa unità temporale (e/o spaziale) e in questa conosciamo il numero medio di volte (che chiameremo lambda) che si manifesta un certo evento



# Distribuzione di Poisson

---

- L'unità spazio-temporale ( $\lambda$ ) è quindi un elemento essenziale per poter applicare la distribuzione di Poisson
- Se prendiamo a riferimento un certo evento e il numero medio di volte in cui questo si manifesta **dobbiamo conoscere con esattezza** anche il tempo o eventualmente lo **spazio** in cui questo si manifesta
- Quando ad esempio diciamo:
  - In un call center chiamano 6 persone all'ora
  - In un negozio entrano 10 persone in una mattinata (4 ore)
  - Il giocatore segna 20 gol all'anno (24 partite)



# Distribuzione di Poisson

- Sia  $X$  la variabile aleatoria con:

**Funzione di probabilità:**  $p_X(x) = P(X = x) = \begin{cases} \frac{\lambda^x}{x!} e^{-\lambda} & \lambda > 0 \\ 0 & altrimenti \end{cases}$

con  $e = 2,718281 \dots$  (numero di Nepero) si dice avere distribuzione Poisson di parametro  $\lambda$

- $\lambda^x$ : rappresenta il contributo proporzionale alla probabilità di osservare  $x$  eventi, ottenuto moltiplicando insieme  $x$  probabilità elementari
  - Esempio: Se in media arrivano  $\lambda = 3$  chiamate al minuto,  $\lambda^2 = 3^2 = 9$  rappresenta il "contributo proporzionale" del verificarsi di 2 chiamate
  - $x!$  tiene conto del **numero di modi diversi in cui gli eventi possono essere ordinati**
    - Esempio: Se  $x = 3$  eventi si verificano, potremmo osservarli in  $3! = 6$  modi distinti (esempio: [A, B, C], [A, C, B], [B, A, C], [B, C, A], [C, A, B], [C, B, A])
    - Poiché la distribuzione di Poisson considera solo *quanti* eventi avvengono in un intervallo → e non *in quale ordine*, dobbiamo dividere per  $x!$  per evitare di contare più volte la stessa configurazione di 3 eventi

# Distribuzione di Poisson

- Sia  $X$  la variabile aleatoria con:

**Funzione di probabilità:**  $p_X(x) = P(X = x) = \begin{cases} \frac{\lambda^x}{x!} e^{-\lambda} & \lambda > 0 \\ 0 & \text{altrimenti} \end{cases}$

con  $e = 2,718281 \dots$  (numero di Nepero)  $0 < p < 1$  si dice avere distribuzione Poisson di parametro  $\lambda$

- Consideriamo  $e^{-\lambda}$  rappresenta la probabilità che non avvenga alcun evento nell'intervallo considerato

- Dal punto di vista matematico, questo deriva dal limite  $(1 - \frac{\lambda}{n})^n \rightarrow e^{-\lambda}$ , che rappresenta la probabilità che tutti i piccoli sotto-intervalli *non* contengano un evento
- Nella formula della Poisson,  $e^{-\lambda}$  funge da fattore di base e garantisce la normalizzazione della distribuzione
- Combinato con  $\lambda^x/x!$ , produce la decrescita delle probabilità per valori di  $x$  molto lontani dal valore medio  $\lambda$
- Il termine  $e^{-\lambda}$  riduce la probabilità di eventi più numerosi rispetto al valore medio  $\lambda$ , riflettendo che eventi molto lontani dal valore atteso ( $\lambda$ ) sono **sempre meno probabili**

- Notazione:  $X \sim P(\lambda)$  indicherà che  $X$  è una variabile aleatoria avente distribuzione di Poisson di parametro  $\lambda$

# Distribuzione di Poisson

- Notazione:  $X \sim P(\lambda)$  indicherà che  $X$  è una variabile aleatoria avente distribuzione di Poisson di parametro  $\lambda$
- Dalla funzione di probabilità si ricava:

$$\frac{p_X(x)}{p_X(x-1)} = \frac{\lambda}{x} \quad x = 1, 2, \dots$$

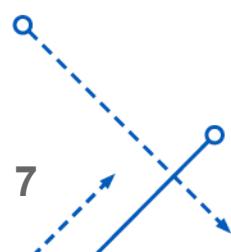
così che le probabilità di Poisson sono calcolabili in modo ricorsivo:

- La probabilità per  $x$  è:  $P(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}$
- La probabilità per  $x - 1$  è:  $P(X = x - 1) = \frac{\lambda^{x-1} e^{-\lambda}}{(x-1)!}$  
- Dividendo  $P(X = x)$  per  $P(X = x - 1)$  si ha:  $\frac{P(X=x)}{P(X=x-1)} = \frac{\frac{\lambda^x}{x!}}{\frac{\lambda^{x-1}}{(x-1)!}} = \frac{\lambda}{x}$
- Isolando  $P(X = x)$  si ha:  $P(X = x) = \frac{\lambda}{x} P(X = x - 1)$
- $P(X = 0) = e^{-\lambda}$
- $P(X = 1) = \frac{\lambda}{1} P(X = 0)$
- $P(X = 2) = \frac{\lambda}{2} P(X = 1)$
- ...
- $P(X = k) = \frac{\lambda}{k} P(X = k - 1)$

# Distribuzione di Poisson

---

- Il numero di volte il cui l'evento si verifica nell'unità spazio temporale è la media di questa distribuzione
  - Ritornando all'esempio di prima:
    - in un call center chiamano 6 persone all'ora
  - Intendiamo dire:
    - in un call center chiamano mediamente 6 persone in un'ora
- Il valore di  $\lambda$  e il valore dell'unità spazio-temporale sono tra di loro strettamente connessi
  - Non ha senso parlare del  $\lambda$  senza la corrispondente unità spazio-temporale
    - in un call center chiamano mediamente 6 persone in **un'ora**
  - Se **raddoppiamo il tempo** in cui l'evento si manifesta mediamente, andremo a **raddoppiare anche il numero di persone**
  - Viceversa, se dividiamo il tempo per 2, divideremo anche il numero di persone medio per 2



# Esempio Giocatore

---

- Esempio: sappiamo che un giocatore è in grado di segnare mediamente 20 gol nell'arco di una stagione (24 partite)

**Qual è la probabilità che nelle prossime 6 partite giocate segni esattamente 6 goal?**

- $\lambda = 20$
- Tempo = 24 partite
- Ora dobbiamo notare che la domanda ci chiede di calcolare la probabilità che il giocatore segni esattamente 6 gol nell'arco delle **prossime 6 partite** giocate
- Adeguiamo il numero medio di gol a 6 partite, ovvero un quarto di stagione:
  - $\lambda = \frac{20}{4} = 5$  con  $\frac{1}{4} = \frac{6}{24}$  cioè  $\frac{1}{4}$  di stagione
  - Tempo  $= \frac{24}{4} = 6$  partite
- Si ha che  $p_X(x) = \frac{\lambda^x}{x!} e^{-\lambda} = \frac{5^6}{6!} e^{-5} = 0,1462$  cioè il 14,62% di probabilità che segni 6 goal nelle prossime 6 partite

# Esempio Giocatore

- Per ricavare i valori della distribuzione di probabilità applichiamo sempre la formula:

$$p_X(x) = \frac{\lambda^x}{x!} e^{-\lambda}$$

e consideriamo  $x$  come il “numero di gol segnati da Ibrahimovic”, si ha che con  $\lambda = 5$ :

$$p_X(0) = \frac{5^0}{0!} e^{-5}$$

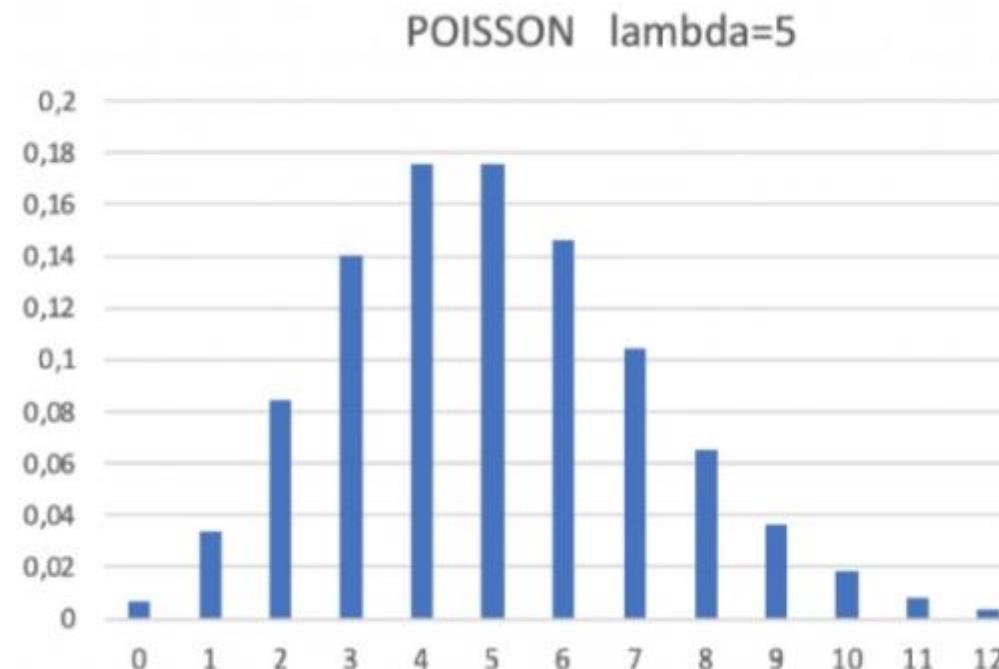
...

$$p_X(2) = \frac{5^2}{2!} e^{-5}$$

...

$$p_X(10) = \frac{5^{10}}{10!} e^{-5}$$

...

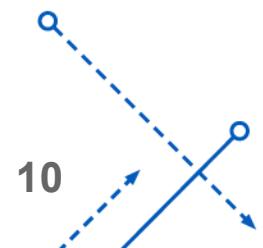


# Distribuzione di Poisson

---

- Esempio: Consideriamo diversi valori se  $\lambda = 0.5, 2.5, 3, 6$  le probabilità di Poisson per  $x = 0, 1, \dots, 10$  possono essere così valutate:

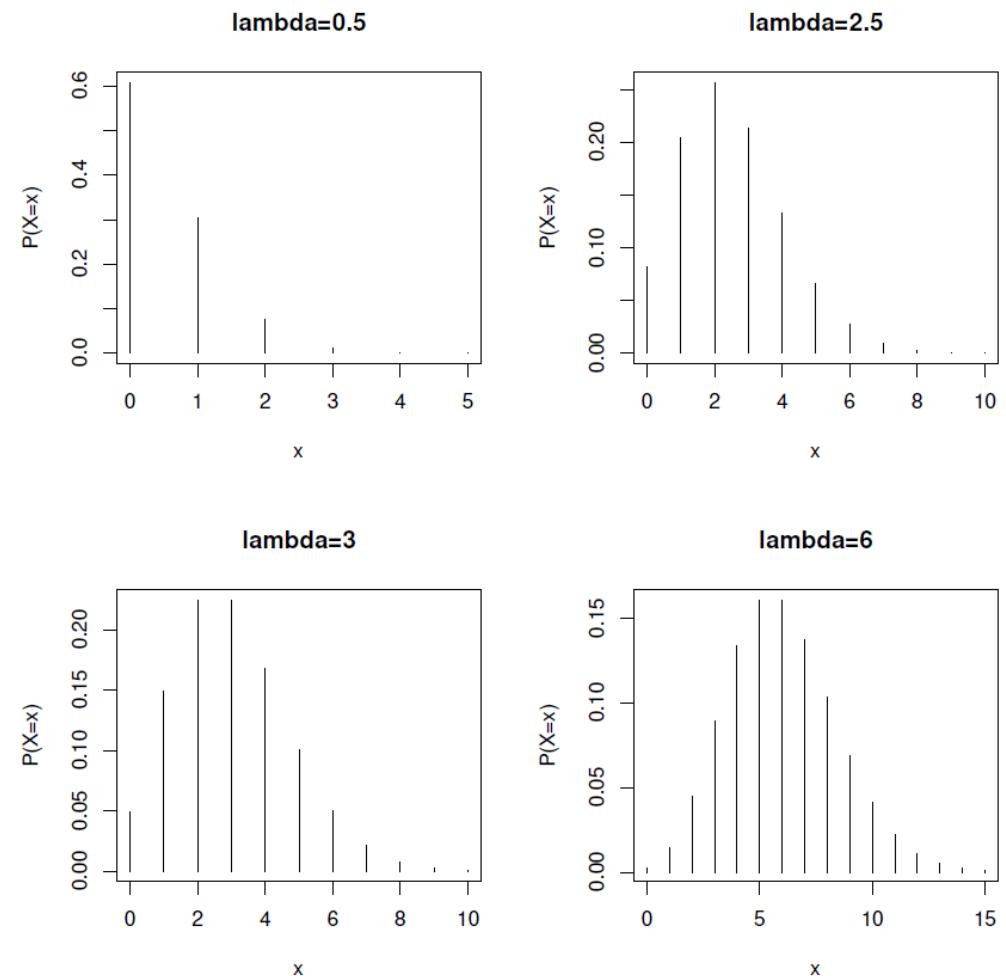
```
>par(mfrow=c(2,2))
>x<-0:5
>plot(x,dpois(x,lambda=0.5),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=0.5")
>
>x<-0:10
>plot(x,dpois(x,lambda=2.5),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=2.5")
>
>x<-0:10
>plot(x,dpois(x,lambda=3),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=3")
>
>x<-0:15
>plot(x,dpois(x,lambda=6),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=6")
```



# Distribuzione di Poisson

- Esempio: Consideriamo diversi valori se  $\lambda = 0.5, 2.5, 3, 6$  le probabilità di Poisson per  $x = 0, 1, \dots, 10$  possono essere così valutate:

```
>par(mfrow=c(2,2))
>x<-0:5
>plot(x,dpois(x,lambda=0.5),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=0.5")
>
>x<-0:10
>plot(x,dpois(x,lambda=2.5),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=2.5")
>
>x<-0:10
>plot(x,dpois(x,lambda=3),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=3")
>
>x<-0:15
>plot(x,dpois(x,lambda=6),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=6")
```

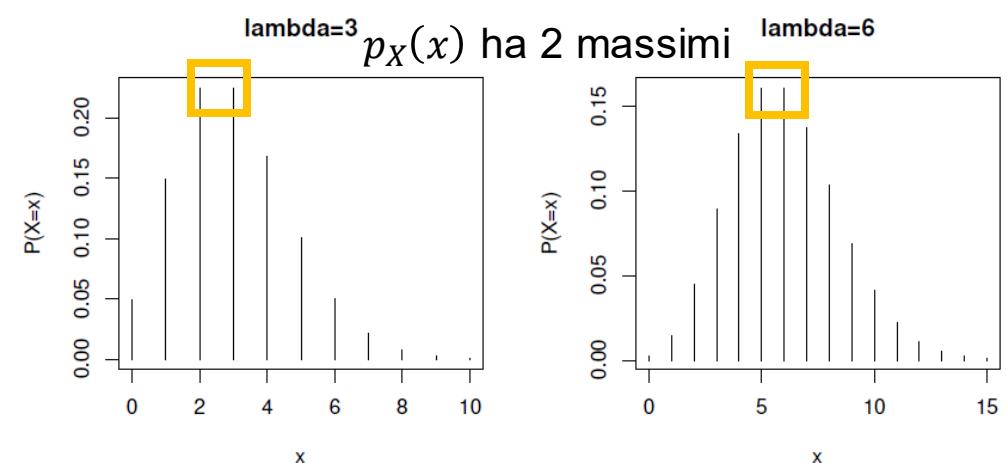
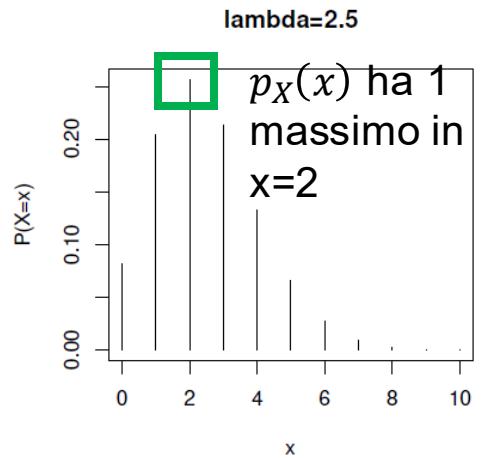
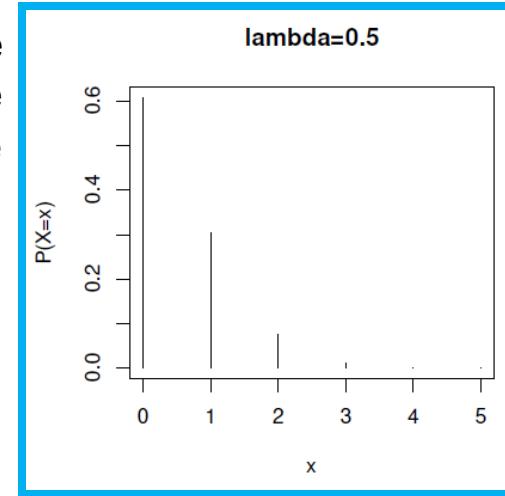


# Distribuzione di Poisson

- Esempio: Consideriamo diversi valori se  $\lambda = 0.5, 2.5, 3, 6$  le probabilità di Poisson per  $x = 0, 1, \dots, 10$  possono essere così valutate:

```
>par(mfrow=c(2,2))
>x<-0:5
>plot(x,dpois(x,lambda=0.5),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=0.5")
>
>x<-0:10
>plot(x,dpois(x,lambda=2.5),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=2.5")
>
>x<-0:10
>plot(x,dpois(x,lambda=3),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=3")
>
>x<-0:15
>plot(x,dpois(x,lambda=6),
+xlab="x",ylab="P(X=x)",type="h",main="lambda=6")
```

$p_X(x)$  è  
strettamente  
decrescente



# Distribuzione di Poisson

---

- Per il calcolo in R delle funzioni di distribuzione si usa

```
ppois(x, lambda, lower.tail = TRUE)
```

dove

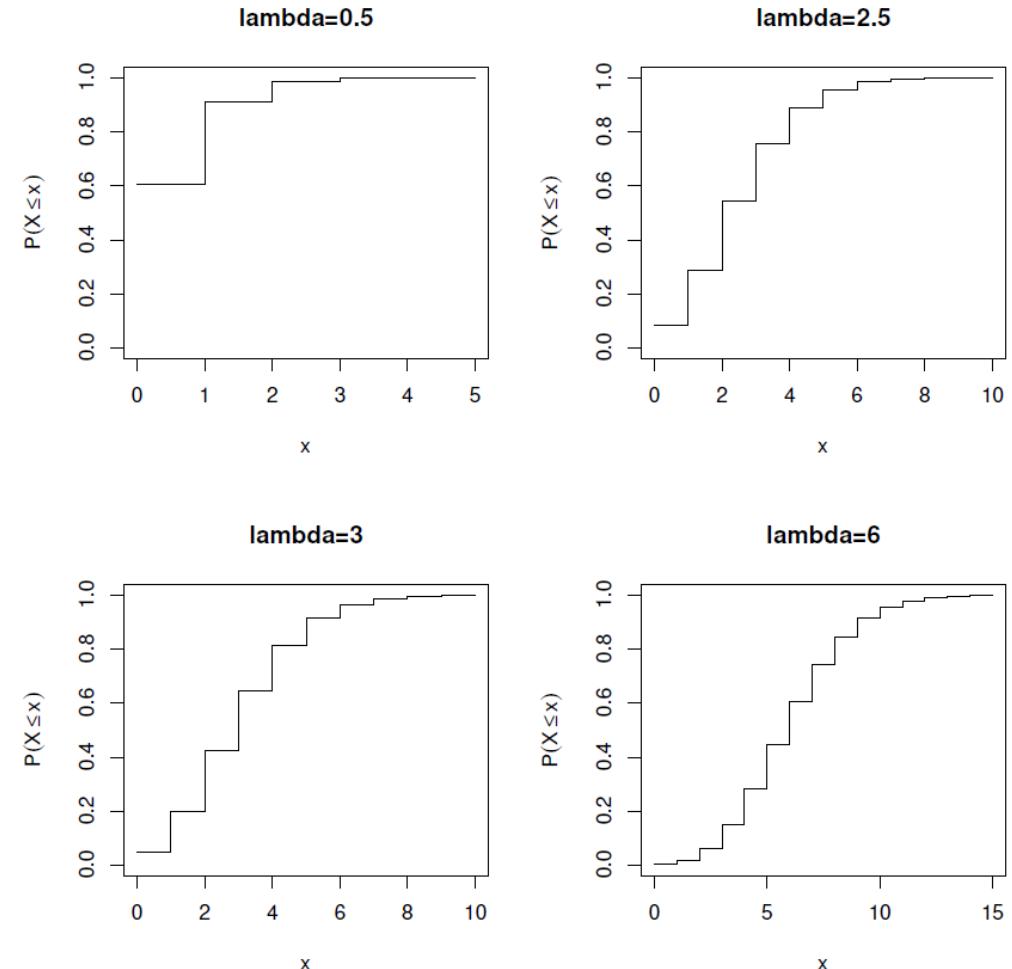
- **x** è il valore assunto (o i valori assunti) dalla variabile aleatoria di Poisson;
  - **lambda** è vettore dei valori medi (non negativi)
  - **lower.tail** se tale parametro è TRUE (caso di default) calcola  $P(X \leq x)$ , mentre se tale parametro è FALSE calcola  $P(X > x)$
- Esempio: se  $\lambda = 5$  le probabilità di Poisson per  $x = 0, 1, \dots, 8$  possono essere così valutate:

```
> x<-0:8  
> ppois(x,lambda=0.5)  
[1] 0.6065307 0.9097960 0.9856123 0.9982484 0.9998279 0.9999858  
[7] 0.9999990 0.9999999 1.0000000
```

# Distribuzione di Poisson

- Esempio: Consideriamo diversi valori se  $\lambda = 0.5, 2.5, 3, 6$  le funzioni di distribuzione di Poisson per  $x = 0, 1, \dots, 8$  possono essere così rappresentate:

```
>par(mfrow=c(2,2))
>x<-0:5
>plot(x,ppois(x,lambda=0.5),
+xlab="x",ylab=expression(P(X<=x)),ylim=c(0,1),type="s",
+main="lambda=0.5")
>
>x<-0:10
>plot(x,ppois(x,lambda=2.5),
+xlab="x",ylab=expression(P(X<=x)),ylim=c(0,1),type="s",
+main="lambda=2.5")
>
>x<-0:10
>plot(x,ppois(x,lambda=3),
+xlab="x",ylab=expression(P(X<=x)),ylim=c(0,1),type="s",
+main="lambda=3")
>
>x<-0:15
>plot(x,ppois(x,lambda=6),
+xlab="x",ylab=expression(P(X<=x)),ylim=c(0,1),type="s",
+main="lambda=6")
```



# Quantili

---

- Per calcolare i quantili (percentili) della si utilizza la funzione basta aggiungere  $n$  ai quantili e alla simulazione della variabile binomiale negativa:

```
qpois(z, lambda)
```

dove

- $z$  è il valore assunto (o i valori assunti) dalle probabilità relative al percentile  $z \cdot 100$ –esimo, cioè il vettore delle probabilità;
- **lambda** è vettore dei valori medi (non negativi)
- Esempio: se  $\lambda = 3$  i quartili  $Q_0, Q_1, Q_2, Q_3, Q_4$  sono:

```
>z<-c(0,0.25,0.5,0.75,1)
> qpois(z,lambda=3)
[1] 0 2 3 4 Inf
```

$$Q_0 = 0, Q_1 = 2, Q_2 = 3, Q_3 = 4, Q_4 = \text{inf}$$

# Quantili

- Esempio:
  - Generiamo una sequenza di 50 numeri pseudocasuali simulando una variabile aleatoria di Poisson con valore medio  $\lambda = 3$ :

```
> sim<-rpois(50,lambda=3)
> sim
[1] 1 1 4 0 3 0 2 1 5 3 2 1 5 2 2 2 5 1 4 2 1 4 2 3 5 4 3 4 0 3 3 1
[33] 7 2 1 2 2 2 3 4 2 1 2 5 1 2 1 4 5 3
> table(sim)
sim
 0   1   2   3   4   5   7
 3 11 14  8  7  6  1
→ Frequenze assolute
> table(sim)/length(sim)
sim
 0     1     2     3     4     5     7
0.06 0.22 0.28 0.16 0.14 0.12 0.02
→ Frequenze relative
```

# Generazione di Osservazioni Sintetiche

- È possibile simulare in R la variabile aleatoria di Poisson generando una sequenza di numeri pseudocasuali mediante la funzione;

```
rpois(N,lambda)
```

dove

- **N** è la lunghezza della sequenza da generare
- **lambda** è vettore dei valori medi (non negativi)
- Ad esempio, se desideriamo generare una sequenza di 50 numeri pseudocasuali simulando una variabile aleatoria di Poisson di valor medio  $\lambda = 3$  si ha:

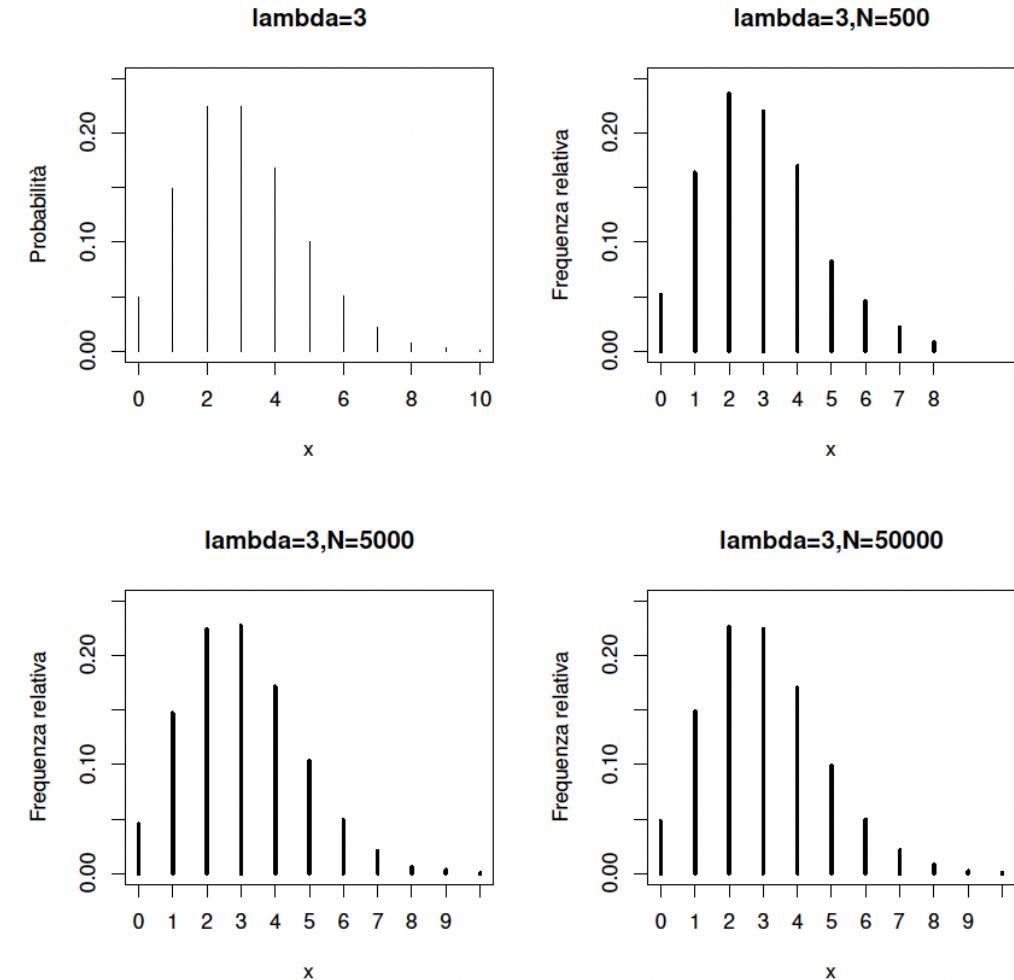
```
> sim<-rpois(50,lambda=3)
> sim
[1] 1 1 4 0 3 0 2 1 5 3 2 1 5 2 2 2 5 1 4 2 1 4 2 3 5 4 3 4 0 3 3 1
[33] 7 2 1 2 2 2 3 4 2 1 2 5 1 2 1 4 5 3
> table(sim)
sim
 0   1   2   3   4   5   7 
 3 11 14  8  7  6  1 
> table(sim)/length(sim)
sim
 0   1   2   3   4   5   7 
0.06 0.22 0.28 0.16 0.14 0.12 0.02
```

# Generazione di Osservazioni Sintetiche

- Confrontiamo la funzione di probabilità di Poisson teorica con quella simulata all'aumentare della lunghezza  $N = 500, 5000, 50000$  della sequenza generata

```
>par(mfrow=c(2,2))
>x<-0:10
>plot(x,dpois(x,lambda=3),xlab="x",ylab="Probabilità ",type="h",
+main="lambda=3",xlim=c(0,10),ylim=c(0,0.25))
>
>sim1<-rpois(500,lambda=3)
>plot(table(sim1)/length(sim1),xlab="x",type="h",
+ylab="Frequenza relativa",xlim=c(0,10),ylim=c(0,0.25),
+main="lambda=3,N=500")
>
>sim2<-rpois(5000,lambda=3)
>plot(table(sim2)/length(sim2),xlab="x",type="h",
+ylab="Frequenza relativa",xlim=c(0,10),ylim=c(0,0.25),
+main="lambda=3,N=5000")
>
>sim3<-rpois(50000,lambda=3)
>plot(table(sim3)/length(sim3),xlab="x",type="h",
+ylab="Frequenza relativa",xlim=c(0,10),ylim=c(0,0.25),
+main="lambda=3,N=50000")
```

Si nota che all'aumentare della lunghezza della sequenza generata il grafico delle frequenze relative si avvicina sempre di più al grafico della funzione di probabilità di Poisson.



# STATISTICA E ANALISI DEI DATI

Distribuzione Ipergeometrica

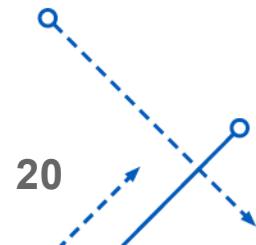
# Distribuzione Ipergeometrica

---

- La distribuzione Ipergeometrica interviene specificamente **nella descrizione di estrazioni senza reinserimento** oppure di estrazioni in blocco
- Si consideri l'esperimento che consiste nell'estrarre  $k$  biglie senza reinserimento da un'urna contenente  $m + n$  biglie, di cui  $m$  sono bianche e  $n$  sono nere ( $0 \leq k \leq m + n$ ) e si consideri l'evento

$$E_r = \{r \text{ delle } k \text{ biglie estratte sono bianche}\} \quad (r = 0, 1, \dots, k)$$

- Esempi:
  - Su 100 pezzi prodotti, 5 sono difettosi. Qual è la probabilità che in un campione di 10 pezzi ci siano almeno 2 difettosi?
  - In un mazzo di 52 carte con 13 cuori, qual è la probabilità di ottenere esattamente 3 cuori pescando 5 carte?
  - In una popolazione di 100 animali, 20 sono marcati. Qual è la probabilità che in un campione di 15 animali ci siano esattamente 4 marcati?
  - In una città di 10.000 abitanti, 3.000 preferiscono il prodotto A. Intervistando 100 persone, qual è la probabilità che almeno 40 preferiscano il prodotto A?
  - ...



# Distribuzione Ipergeometrica

---

- La distribuzione Ipergeometrica interviene specificamente **nella descrizione di estrazioni senza reinserimento** oppure di estrazioni in blocco
- Si consideri l'esperimento che consiste nell'estrarre  $k$  biglie senza reinserimento da un'urna contenente  $m + n$  biglie, di cui  $m$  sono bianche e  $n$  sono nere ( $0 \leq k \leq m + n$ ) e si consideri l'evento

$$E_r = \{r \text{ delle } k \text{ biglie estratte sono bianche}\} \quad (r = 0, 1, \dots, k)$$

Facendo ricorso alla definizione classica di probabilità si ha:

$$P(E_r) = \frac{\binom{m}{r} \binom{n}{k-r}}{\binom{m+n}{k}}$$

con  $0 \leq r \leq m$  e  $0 \leq k - r \leq n$ , ossia:

$$\max(0, k - n) \leq r \leq \min(m, k)$$

# Distribuzione Ipergeometrica

$$E_r = \{r \text{ delle } k \text{ biglie estratte sono bianche}\} \quad (r = 0, 1, \dots, k)$$

Facendo ricorso alla definizione classica di probabilità si ha:

È il numero di modi per scegliere le  $r$  biglie bianche dalle  $m$  disponibili

Numero di modi in cui si estrarre  $k$  delle  $m + n$  biglie nell'urna

$$P(E_r) = \frac{\binom{m}{r} \binom{n}{k-r}}{\binom{m+n}{k}}$$

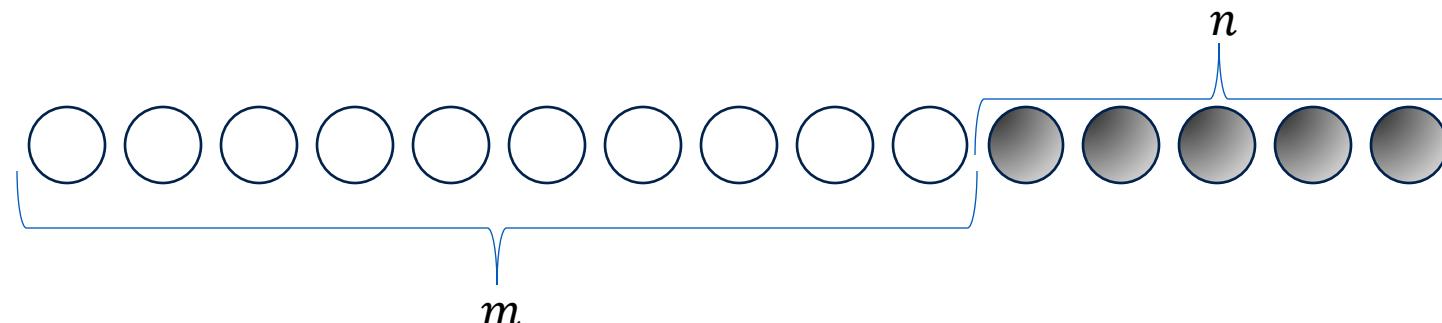
è il numero di modi per scegliere le restanti  $k - r$  biglie (che devono essere nere) dalle  $n$  disponibili.

con  $0 \leq r \leq m$  e  $0 \leq k - r \leq n$ , ossia:

$$\max(0, k - n) \leq r \leq \min(m, k)$$

**Esempio:**  $m = 10, n = 5, k = 8$ . Anche se volessi 0 biglie bianche, non potresti averle, perché  $n = 5 < k = 8$ .

Dovremmo per forza pescare almeno  $k - n = 8 - 5 = 3$  biglie bianche. Quindi  $r \geq 3$



# Distribuzione Ipergeometrica

- Sia  $X$  la variabile aleatoria che descrive il numero di biglie bianche estratte senza reinserimento, risulta  $X = r$  se e solo se si verifica l'evento  $E_r$

**Funzione di probabilità:**  $p_X(x) = \begin{cases} \frac{\binom{m}{x} \binom{n}{k-x}}{\binom{m+n}{k}} & \max(0, k-n) \leq r \leq \min(m, k) \\ 0 & \text{altrimenti} \end{cases}$

con  $n, m, k$  interi tali che  $0 \leq k \leq m + n$  si dice avere distribuzione Ipergeometrica di parametri  $n, m, k$

- Notazione:

- $X \sim I(m, n, k)$  indicherà che  $X$  è una variabile aleatoria avente distribuzione Ipergeometrica di parametri  $m, n, k$

# Valore Atteso

- Possiamo definire **variabili aleatorie**:

$$X_i = \begin{cases} 1 & \text{se la } i\text{-esima biglia estratta è bianca} \\ 0 & \text{altrimenti} \end{cases}$$

per  $i = 1, 2, \dots, k$ .

- Allora sia  $X = X_1 + X_2 + \dots + X_k$ . Per la linearità del valore atteso:  $E[X] = E[\sum_{i=1}^k X_i] = \sum_{i=1}^k E[X_i]$

- Sia  $N = m + n$ , calcoliamo  $E[X_i]$ :

- Alla prima estrazione:  $P(X_1 = 1) = \frac{m}{N}$
- Alla seconda estrazione:  $P(X_2 = 1) = \frac{m}{N}$  (per simmetria!)
- Infatti, la probabilità che la seconda biglia sia bianca è:

$$\frac{m}{N} \cdot \frac{m-1}{N-1} + \frac{N-m}{N} \cdot \frac{m}{N-1} = \frac{m}{N}$$

- Quindi per ogni  $i$ :  $E[X_i] = \frac{m}{N}$

- **Risultato finale:**

$$E[X] = \sum_{i=1}^k \frac{m}{N} = k \cdot \frac{m}{N} \quad \text{con } N = n + m$$

Calcoliamo  $P(X_2 = 1)$  usando la probabilità totale:

$$\begin{aligned} P(X_2 = 1) &= \\ P(X_1 = 1) \cdot P(X_2 = 1 | X_1 = 1) &+ P(X_1 = 0) \\ &\cdot P(X_2 = 1 | X_1 = 0) \end{aligned}$$

Sostituiamo:

$$\bullet P(X_1 = 1) = \frac{m}{N}$$

$$\bullet P(X_1 = 0) = \frac{N-m}{N}$$

$\bullet P(X_2 = 1 | X_1 = 1) = \frac{m-1}{N-1}$ ) se la prima era bianca,  
ne rimangono  $m-1$  su  $N-1$ )

$\bullet P(X_2 = 1 | X_1 = 0) = \frac{m}{N-1}$ ) se la prima era nera,  
rimangono tutte le  $m$  bianche su  $N-1$ )

$$P(X_2 = 1) = \frac{m}{N} \cdot \frac{m-1}{N-1} + \frac{N-m}{N} \cdot \frac{m}{N-1}$$

# Distribuzione Ipergeometrica

---

- Il valore medio e la varianza della distribuzione ipergeometrica risultano essere:

$$\textbf{Valore atteso: } E(X) = k \frac{m}{m+n}$$

$$\textbf{Varianza: } Var(X) = k \frac{mn}{(m+n)^2} \frac{m+n-k}{m+n-1}$$

- Nota:** Se poniamo  $p = \frac{m}{m+n}$  si nota che la media della distribuzione ipergeometrica coincide con la media di una variabile aleatoria binomiale  $X \sim B(k, p)$  e la varianza della distribuzione ipergeometrica è  $\frac{m+n-k}{m+n-1}$  volte la varianza della distribuzione binomiale

# Distribuzione Ipergeometrica

---

- Il valore medio e la varianza della distribuzione ipergeometrica risultano essere:

$$\textbf{Valore atteso: } E(X) = k \frac{m}{m+n}$$

$$\textbf{Varianza: } Var(X) = k \frac{mn}{(m+n)^2} \frac{m+n-k}{m+n-1}$$

- Nota:** Se poniamo  $p = \frac{m}{m+n}$  si nota che la media della distribuzione ipergeometrica coincide con la media di una variabile aleatoria binomiale  $X \sim B(k, p)$  e la varianza della distribuzione ipergeometrica è  $\frac{m+n-k}{m+n-1}$  volte la varianza della distribuzione binomiale
- Per il calcolo in R della funzione di probabilità si utilizza la funzione:

```
dhyper(x, m, n, k)
```

dove

- $x$  è il valore assunto (o i valori assunti) dalla variabile aleatoria ipergeometrica considerata;
- $m$  indica il numero di palline bianche nell'urna;
- $n$  indica il numero di palline nere nell'urna;
- $k$  il numero di palline estratte dall'urna

# Distribuzione Ipergeometrica

---

- Esempio: Consideriamo:
  - Il numero di palline bianche nell'urna è  $m = 12$
  - Il numero di palline nere nell'urna è  $n = 36$
  - Il numero di palline estratte dall'urna è  $k = 5$ ,
  - $\max(0, k - n) = 0$  e  $\min(m, k) = 5$
  - $x$  rappresenta il numero di palline bianche estratte senza reinserimento da un'urna che contiene sia palline bianche che nere

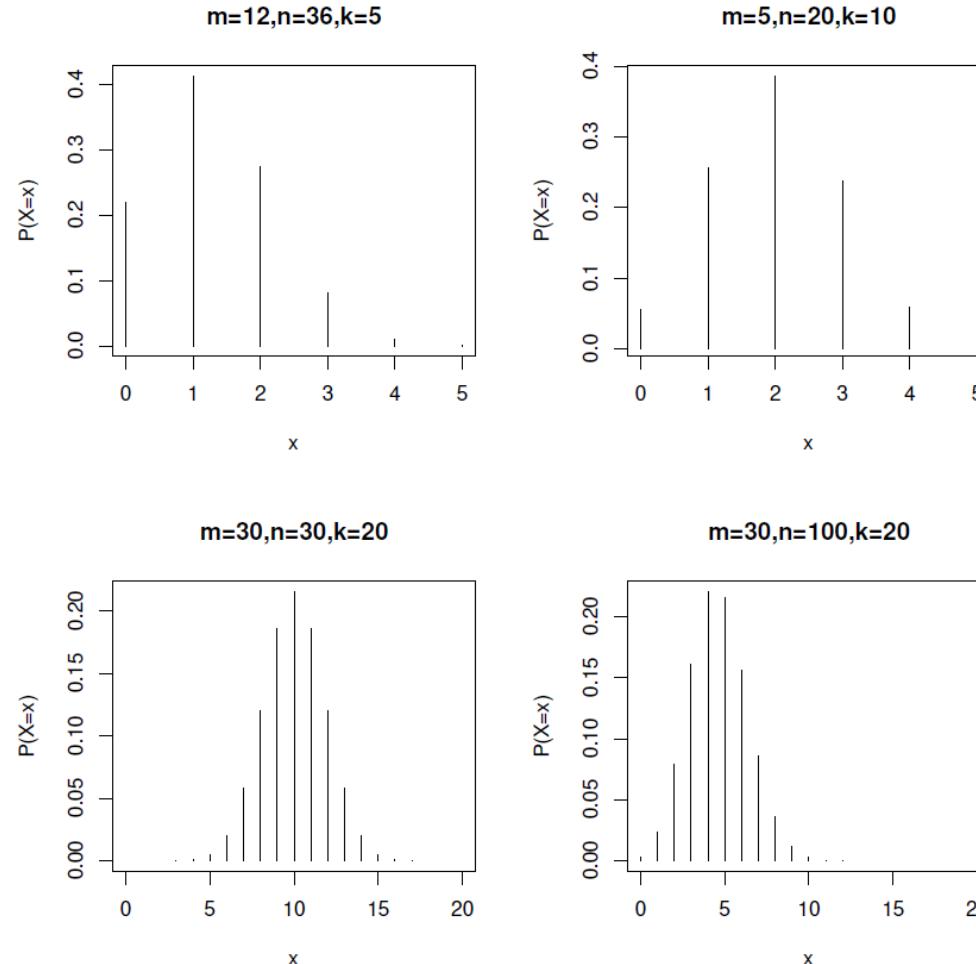
Le probabilità ipergeometriche possono essere così valutate:

```
> x<-0:5  
> dhyper(x,12,36,5)  
[1] 0.2201665125 0.4128122109 0.2752081406 0.0809435708  
[5] 0.0104070305 0.0004625347
```

# Distribuzione Ipergeometrica

- Esempio: Visualizziamo le funzioni di probabilità ipergeometrica facendo variare  $k, m, n$ :

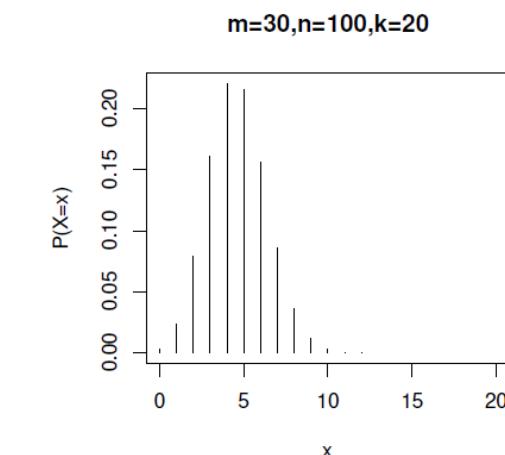
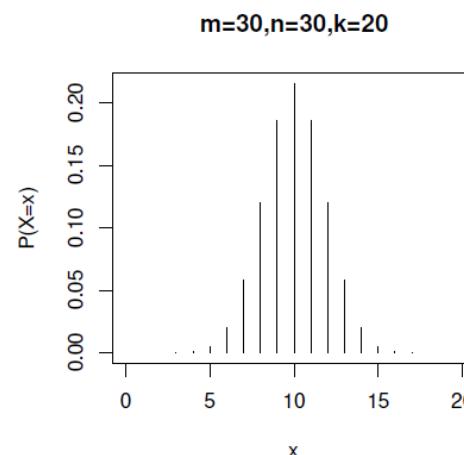
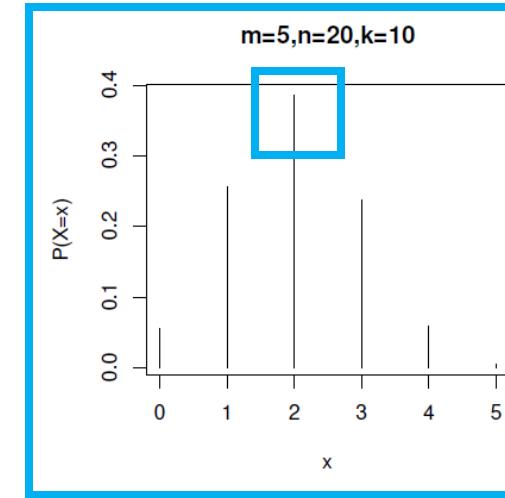
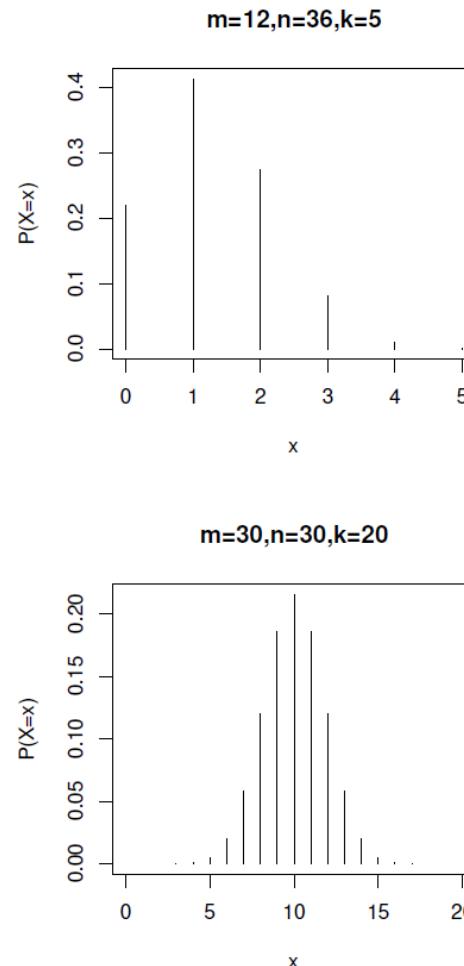
```
>par(mfrow=c(2, 2))
>x<-0:5
>plot(x ,dhyper(x ,12 ,36 ,5) ,
+ xlab="x" ,ylab="P(X=x)" ,type="h" ,
+ main="m=12 ,n=36 ,k=5")
>
>x<-0:5
>plot(x ,dhyper(x ,5 ,20 ,10) ,
+ xlab="x" ,ylab="P(X=x)" ,type="h" ,
+ main="m=5 ,n=20 ,k=10")
>x<-0:20
>plot(x ,dhyper(x ,30 ,30 ,20) ,
+ xlab="x" ,ylab="P(X=x)" ,type="h" ,
+ main="m=30 ,n=30 ,k=20")
>
>x<-0:20
>plot(x ,dhyper(x ,30 ,100 ,20) ,
+ xlab="x" ,ylab="P(X=x)" ,type="h" ,
+ main="m=30 ,n=100 ,k=20")
```



# Distribuzione Ipergeometrica

- Esempio: Visualizziamo le funzioni di probabilità ipergeometrica facendo variare  $k, m, n$ :

```
>par(mfrow=c(2, 2))
>x<-0:5
>plot(x ,dhyper(x ,12 ,36 ,5) ,
+ xlab="x" ,ylab="P(X=x)" ,type="h" ,
+ main="m=12 ,n=36 ,k=5")
>
>x<-0:5
>plot(x ,dhyper(x ,5 ,20 ,10) ,
+ xlab="x" ,ylab="P(X=x)" ,type="h" ,
+ main="m=5 ,n=20 ,k=10")
>x<-0:20
>plot(x ,dhyper(x ,30 ,30 ,20) ,
+ xlab="x" ,ylab="P(X=x)" ,type="h" ,
+ main="m=30 ,n=30 ,k=20")
>
>x<-0:20
>plot(x ,dhyper(x ,30 ,100 ,20) ,
+ xlab="x" ,ylab="P(X=x)" ,type="h" ,
+ main="m=30 ,n=100 ,k=20")
```



Il caso più probabile è che 2 delle  $k$  biglie pescate siano bianche

# Distribuzione Ipergeometrica

---

- Per il calcolo in R della funzione di distribuzione si utilizza la funzione:

```
phyper(x, m, n, k, lower.tail = TRUE)
```

dove

- **x** è il valore assunto (o i valori assunti) dalla variabile aleatoria ipergeometrica considerata;
- **m** indica il numero di palline bianche nell'urna;
- **n** indica il numero di palline nere nell'urna;
- **k** il numero di palline estratte dall'urna
- **lower.tail** se tale parametro è TRUE (caso di default) calcola  $P(X \leq x)$ , mentre se tale parametro è FALSE calcola  $P(X > x)$

# Distribuzione Ipergeometrica

---

- Esempio: Consideriamo l'esempio precedente con: il numero di palline bianche nell'urna è  $m = 12$ ; il numero di palline nere nell'urna è  $n = 36$ ; il numero di palline estratte dall'urna è  $k = 5$  si ha che:

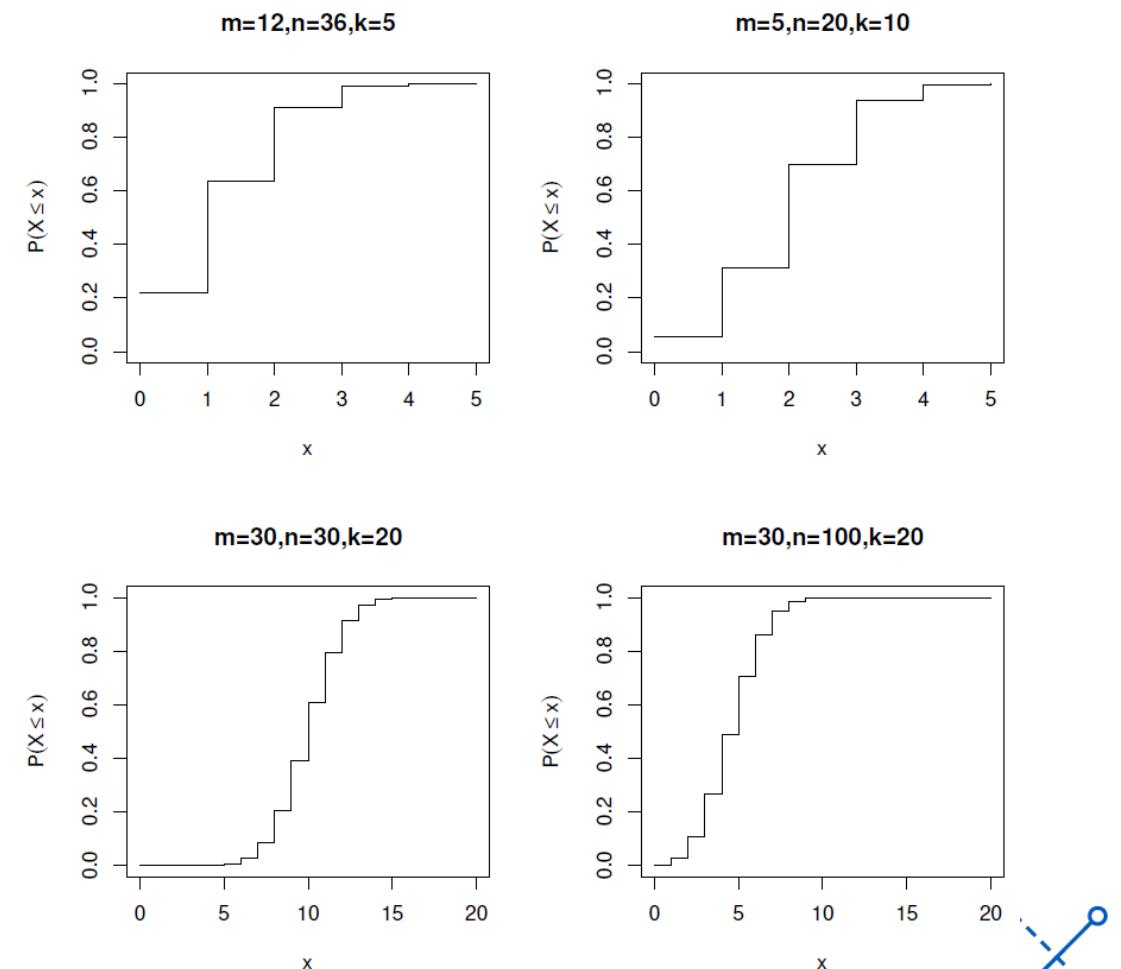
```
> x<-0:5  
> phyper(x,12,36,5)  
[1] 0.2201665 0.6329787 0.9081869 0.9891304 0.9995375 1.0000000
```

# Distribuzione Ipergeometrica

- Esempio: Consideriamo l'esempio precedente con: il numero di palline bianche nell'urna è  $m = 12$ ; il numero di palline nere nell'urna è  $n = 36$ ; il numero di palline estratte dall'urna è  $k = 5$  si ha che:

```
> x<-0:5
> phyper(x,12,36,5)
[1] 0.2201665 0.6329787 0.9081869 0.9891304 0.9995375 1.0000

>par(mfrow=c(2,2))
>x<-0:5
>plot(x,phyper(x,12,36,5),
+xlab="x",ylab=expression(P(X<=x)),ylim=c(0,1),type="s",
+main="m=12,n=36,k=5")
>
>x<-0:5
>plot(x,phyper(x,5,20,10),
+xlab="x",ylab=expression(P(X<=x)),ylim=c(0,1),type="s",
+main="m=5,n=20,k=10")
>
>x<-0:20
>plot(x,phyper(x,30,30,20),
+xlab="x",ylab=expression(P(X<=x)),ylim=c(0,1),type="s",
+main="m=30,n=30,k=20")
>
>x<-0:20
>plot(x,phyper(x,30,100,20),
+xlab="x",ylab=expression(P(X<=x)),ylim=c(0,1),type="s",
+main="m=30,n=100,k=20")
```



# Quantili

---

- Per calcolare i quantili (percentili) della distribuzione Ipergeometrica si utilizza la funzione

```
qhyper(z, m, n, k)
```

dove

- **z** è il valore assunto (o i valori assunti) dalle probabilità relative al percentile  $z \cdot 100$ -esimo;
  - **m** indica il numero di palline bianche nell'urna;
  - **n** indica il numero di palline nere nell'urna;
  - **k** il numero di palline estratte dall'urna
- Esempio: se  $m = 5, n = 20, k = 10$  i quartili  $Q_0, Q_1, Q_2, Q_3, Q_4$  sono:

```
> z<-c(0,0.25,0.5,0.75,1)
> qhyper(z,5,20,10)
[1] 0 1 2 3 5
```

$$Q_0 = 0, Q_1 = 1, Q_2 = 2, Q_3 = 3, Q_4 = 5$$

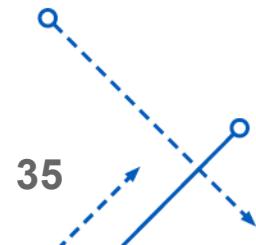
# Esempio

---

- Esempio:
  - Un produttore di computer decide di acquistare monitor da una nuova start-up che rivendica severi standard di controllo della qualità
  - Il produttore ordina 150 monitor e decide di accettare il lotto a condizione che un campione casuale di dimensione 25 non riveli monitor difettosi
  - Se il lotto di 150 monitor contiene 3 monitor difettosi, si desidera determinare la probabilità che il lotto venga accettato
- Denotiamo con  $X$  la variabile aleatoria che rappresenta il numero di monitor non difettosi nel campione. Si nota che  $X \sim I(147, 3, 25)$ . La probabilità richiesta è:

$$P(X = 25) = \frac{\binom{147}{25} \binom{3}{25-25}}{\binom{150}{25}} = 0.5764$$

```
> dhyper(25, 147, 3, 25)
[1] 0.576365
```



# Da Ipergeometrica a Binomiale

- Sia  $X$  la variabile aleatoria Ipergeometrica che rappresenta l'evento dell'estrazione di  $k$  biglie senza reinserimento da un'urna contenente  $m + n$  biglie, di cui  $m$  sono bianche e  $n$  sono nere
- Se  $m$  e  $n$  divergono in modo che  $\frac{m}{m+n}$  converga ad un valore  $p \in (0,1)$  allora:

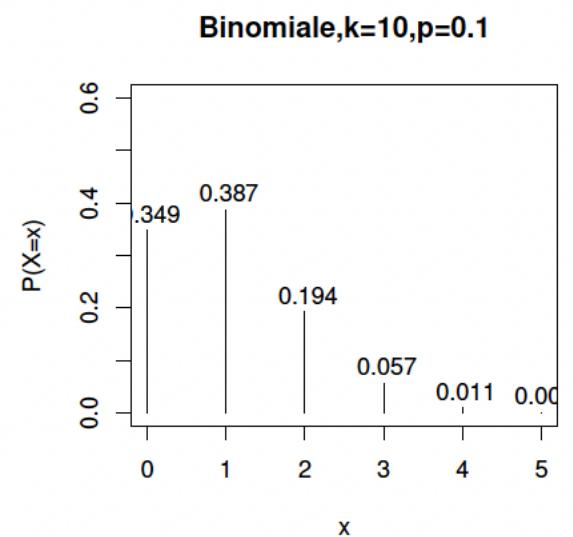
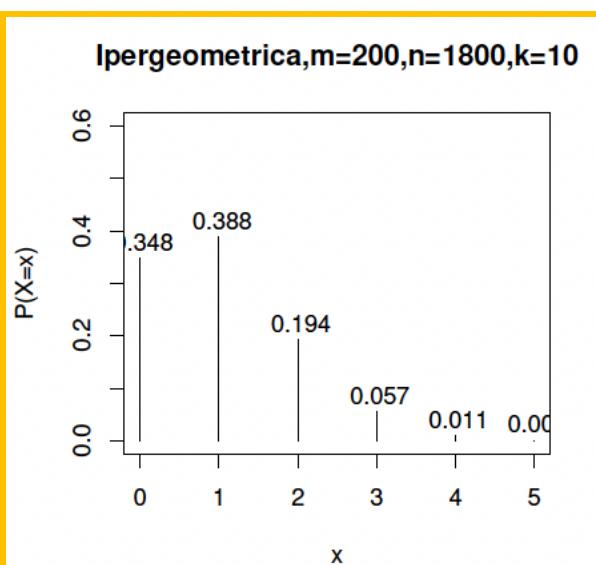
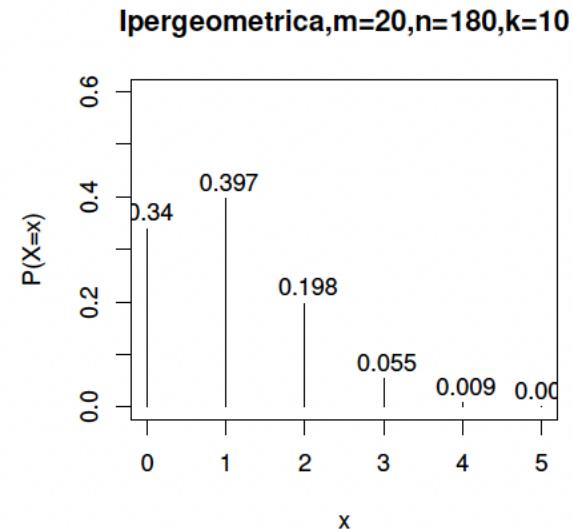
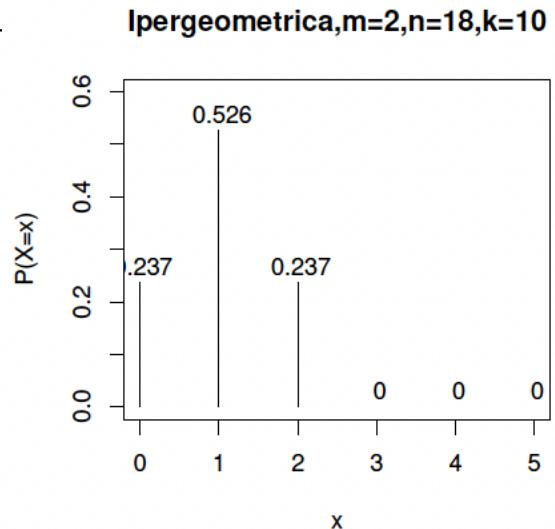
$$\lim_{\substack{m \rightarrow +\infty, m+n \rightarrow +\infty \\ m/(m+n) \rightarrow p}} p_X(x) = \binom{k}{x} p^x (1-p)^{k-x} \quad (x = 0, 1, \dots, k)$$

- Partendo da  $P(E_r) = \frac{\binom{m}{r} \binom{n}{k-r}}{\binom{m+n}{k}}$ , si ha che:
  - se il numero  $m$  delle biglie bianche e il numero  $m + n$  di biglie presenti nell'urna sono entrambi sufficientemente elevati in modo tale che il loro rapporto sia una costante  $p$ ,
  - Si ha che la probabilità che  $X$  delle  $k$  biglie estratte senza reinserimento siano bianche è approssimabile con la medesima probabilità relativa al caso di estrazioni con reinserimento

$$\frac{\binom{m}{x} \binom{n}{k-x}}{\binom{m+n}{k}} \simeq \binom{k}{x} \left( \frac{m}{m+n} \right)^x \left( 1 - \frac{m}{m+n} \right)^{k-x} \quad (x = 0, 1, \dots, k).$$

# Da Ipergeometrica a Binomiale

```
>par(mfrow=c(2,2))
>x<-0:5
>plot(x,dhyper(x,2,18,10),
+ xlab="x",ylab="P(X=x)",type="h",ylim=c(0,0.6),
+ main="Ipergeometrica ,m=2,n=18,k=10")
>y1<-round(dhyper(x,2,18,10),3)
>text(x+0.04,dhyper(x,2,18,10)+0.03,y1)
>
>x<-0:5
>plot(x,dhyper(x,20,180,10),
+ xlab="x",ylab="P(X=x)",type="h",ylim=c(0,0.6),
+ main="Ipergeometrica ,m=20,n=180,k=10")
>y2<-round(dhyper(x,20,180,10),3)
>text(x+0.04,dhyper(x,20,180,10)+0.03,y2)
>
>x<-0:5
>plot(x,dhyper(x,200,1800,10),
+ xlab="x",ylab="P(X=x)",type="h",ylim=c(0,0.6),
+ main="Ipergeometrica ,m=200,n=1800,k=10")
>y3<-round(dhyper(x,200,1800,10),3)
>text(x+0.04,dhyper(x,200,1800,10)+0.03,y3)
>
>x<-0:5
>plot(x,dbinom(x,size=10,prob=0.1),
+ xlab="x",ylab="P(X=x)",type="h",ylim=c(0,0.6),
+ main="Binomiale ,k=10,p=0.1")
>y4<-round(dbinom(x,size=10,prob=0.1),3)
>text(x+0.04,dbinom(x,size=10,prob=0.1)+0.03,y4)
```



# STATISTICA E ANALISI DEI DATI

Sommario

# Funzioni di probabilità di variabili aleatorie discrete

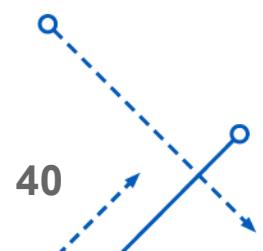
Distribuzione	Notazione	Funzione di probabilità
Bernoulli	$X \sim \mathcal{B}(1, p)$	$p_X(x) = \begin{cases} 1 - p, & x = 0 \\ p, & x = 1 \\ 0, & \text{altrimenti} \end{cases} \quad (0 < p < 1)$
Binomiale	$X \sim \mathcal{B}(n, p)$	$p_X(x) = \begin{cases} \binom{n}{x} p^x (1 - p)^{n-x}, & x = 0, 1, \dots, n \\ 0, & \text{altrimenti} \end{cases}$ $(n = 1, 2, \dots; 0 < p < 1)$
Geometrica	$X \sim \mathcal{BN}(1, p)$	$p_X(x) = \begin{cases} p (1 - p)^x, & x = 0, 1, \dots \\ 0, & \text{altrimenti} \end{cases} \quad (0 < p < 1)$
Geometrica modificata	$X \sim \mathcal{BN}^*(1, p)$	$p_X(x) = \begin{cases} p (1 - p)^{x-1}, & x = 1, 2, \dots \\ 0, & \text{altrimenti} \end{cases} \quad (0 < p < 1)$

Binomiale negativa	$X \sim \mathcal{BN}(n, p)$	$p_X(x) = \begin{cases} \binom{n+x-1}{x} p^n (1-p)^x, & x = 0, 1, \dots \\ 0, & \text{altrimenti} \end{cases}$ $(n = 1, 2, \dots; 0 < p < 1)$
Binomiale negativa modificata	$X \sim \mathcal{BN}^*(n, p)$	$p_X(x) = \begin{cases} \binom{x-1}{n-1} p^n (1-p)^{x-n}, & x = n, n+1, \dots \\ 0, & \text{altrimenti} \end{cases}$ $(n = 1, 2, \dots; 0 < p < 1)$
Poisson	$X \sim \mathcal{P}(\lambda)$	$p_X(x) = \begin{cases} \frac{\lambda^x}{x!} e^{-\lambda}, & x = 0, 1, \dots \\ 0, & \text{altrimenti} \end{cases} \quad (\lambda > 0)$
Ipergeometrica	$X \sim \mathcal{I}(n, m, k)$	$p_X(x) = \begin{cases} \frac{\binom{m}{x} \binom{n}{k-x}}{\binom{m+n}{k}}, & x \geq \max\{0, k-n\} \\ 0, & x \leq \min\{m, k\} \\ & \text{altrimenti} \end{cases}$ $(0 \leq k \leq m+n)$

# Valori medi, varianze e coefficienti di variazione

Nome	$E(X)$	$\text{Var}(X)$	$\text{CV}(X)$
Bernoulli	$p$	$p(1 - p)$	$\sqrt{\frac{1 - p}{p}}$
Binomiale	$np$	$np(1 - p)$	$\sqrt{\frac{1 - p}{np}}$
Geometrica	$(1 - p)/p$	$(1 - p)/p^2$	$1/\sqrt{1 - p}$
Geometrica modificata	$1/p$	$(1 - p)/p^2$	$\sqrt{1 - p}$

Binomiale negativa	$n(1 - p)/p$	$n(1 - p)/p^2$	$1/\sqrt{(1 - p)/n}$
Binomiale negativa modificata	$n/p$	$n(1 - p)/p^2$	$\sqrt{(1 - p)/n}$
Poisson	$\lambda$	$\lambda$	$1/\sqrt{\lambda}$
Ipergeometrica	$k \frac{m}{m + n}$	$k \frac{mn}{(m + n)^2} \frac{m + n - k}{m + n - 1}$	$\sqrt{\frac{n(m + n - k)}{k m (m + n - 1)}}$



# Funzioni in R

Nome	Probabilità Distribuzione	Quantili	Simulazione		Binomiale negativa	dnbnom(x, size, prob) pnbinom(x, size, prob)	qnbinom(z, size, prob)	rnbnom(x, size, prob)
Bernoulli	dbinom(x,1,prob) pbinom(x,1,prob)	qbinom(z,1,prob)	rbinom(N,1,prob)		Binomiale negativa modificata	dnbnom(x-n, size, prob) pnbinom(x-n, size, prob)	qnbinom(z, size, prob)+n	rnbnom(x, size, prob)+n
Binomiale	dbinom(x,size,prob) pbinom(x,size,prob)	qbinom(z,size,prob)	rbinom(N,size,prob)		Poisson	dpois(x,lambda) ppois(x,lambda)	qpois(z,lambda)	rpois(N,lambda)
Geometrica	dgeom(x, prob) pgeom(x, prob)	qgeom(z, prob)	rgeom(N, prob)		Ipergeometrica	dhyper(x, m, n, k) phyper(x, m, n, k)	qhyper(z, m, n, k)	rhyper(N, m, n, k)
Geometrica modificata	dgeom(x-1, prob) pgeom(x-1, prob)	qgeom(z, prob)+1	rgeom(N, prob)+1					