

STATISTICA E ANALISI DEI DATI


Capitolo 14 – Verifica delle Ipotesi

Dott. Stefano Cirillo
Dott. Luigi Di Biasi

a.a. 2025-2026

Criterio del chi-quadrato

- Ci siamo finora occupati di ricavare informazioni da un campione estratto da una popolazione descritta da una variabile aleatoria X caratterizzata da una funzione di probabilità o densità di probabilità $f(x; \vartheta)$
 - stimando il parametro/i non noto/i ϑ della popolazione con stime puntuali ed intervallari
- Vogliamo ora verificare se il campione osservato può **essere stato estratto** da una popolazione descritta da una variabile aleatoria X con funzione di distribuzione $F_X(x)$
 - Utilizzeremo il criterio di verifica **delle ipotesi del chi-quadrato**, detto anche test del chi-quadrato o test del buon adattamento



Criterio del chi-quadrato bilaterale


- Vogliamo verificare l'ipotesi che un certa popolazione, descritta da una variabile aleatoria X , sia caratterizzata da una funzione di distribuzione $F_X(x)$, con k parametri **non noti** da stimare
- Denotiamo con:
 - **H_0** l'**ipotesi nulla** soggetta a verifica
 - **H_1** l'**ipotesi alternativa**

il test chi-quadrato con livello di significatività α mira a verificare:

- **H_0** : X ha una funzione di distribuzione $F_X(x)$
- **H_1** : X non ha una funzione di distribuzione $F_X(x)$

considerando α come la probabilità massima di rifiutare l'ipotesi nulla quando essa è vera

- Occorre **determinare un test** con livello di significatività α che permetta di determinare una regione di accettazione e di rifiuto dell'ipotesi nulla
 - Il test di verifica delle ipotesi considerato è bilaterale (o a due code)



Criterio del chi-quadrato bilaterale

- Suddividiamo l'insieme dei valori che la variabile aleatoria X può assumere in r **sottoinsiemi / intervalli** I_1, I_2, \dots, I_r in modo che la probabilità p_i che la variabile aleatoria assuma un valore appartenente I_i :

$$p_i \in P(X \in I_i)$$

- Estraiamo un campione x_1, x_2, \dots, x_n di ampiezza n
 - Osserviamo le **frequenze assolute** del campione n_1, n_2, \dots, n_r con cui gli n elementi si **distribuiscono** nei rispettivi insiemi I_1, I_2, \dots, I_r
- Si ha quindi che:

$$p_i \geq 0 \text{ con } \sum_{i=1}^r p_i = 1$$

La somma delle probabilità che X assuma un valore appartenente I_i è 1


$$n_i \geq 0 \text{ con } \sum_{i=1}^n n_i = n \quad (i = 1, 2, \dots, r)$$

La somma delle frequenze con cui gli elementi si distribuiscono nei rispettivi insiemi è uguale alla grandezza del campione n

Selezione degli Intervalli

- Gli intervalli permettono di suddividere il dominio della variabile casuale X in un numero finito di classi o categorie
- Questi intervalli sono fondamentali per **calcolare le frequenze osservate** e attese e verificare se la distribuzione empirica di X è coerente con la distribuzione teorica $F_X(x)$
 - Si suddivide il dominio di X in r intervalli disgiunti I_1, I_2, \dots, I_r , che coprono tutto il dominio della variabile
 - Gli estremi degli intervalli possono essere scelti in modo equidistante o meno, a seconda della distribuzione di $F_X(x)$
 - Gli intervalli devono essere definiti in modo tale **che il numero di osservazioni attese in ciascun intervallo sia sufficientemente grande, idealmente maggiore o uguale a 5**
 - Questo assicura che l'approssimazione del chi quadrato sia valida.

$$\min(np_1, np_2, \dots, np_r) \geq 5$$



Criterio del chi-quadrato bilaterale

- Si nota che la probabilità:

$$p(n_1, n_2, \dots, n_r) = \frac{n!}{n_1!n_2!\dots n_r!} p_1^{n_1} p_2^{n_2} \dots p_r^{n_r}$$

Probabilità che esattamente n_1 elementi appartengano ad I_1 , n_2 elementi appartengano ad I_2 , ..., n_r elementi appartengano ad I_r

è la probabilità di una specifica distribuzione dei conteggi n_1, n_2, \dots, n_r tra gli r intervalli I_1, I_2, \dots, I_r ed è basata sulla distribuzione multinomiale

- Approssimazione normale per grandi campioni**

- Per n grande, per il **teorema del limite centrale**:

- Ogni N_i ha media np_i e varianza $np_i(1 - p_i)$.
- I termini non sono indipendenti perché $\sum N_i = n$.
- La distribuzione congiunta di (N_1, \dots, N_r) è approssimativamente normale

- Si calcola poi la quantità:

$$\chi^2 = \sum_{i=1}^r \left(\frac{n_i - np_i}{\sqrt{np_i}} \right)^2$$

Numero medio di elementi che cadono nell'intervallo I_i è np_i


Criterio del chi-quadrato bilaterale

- Se la variabile aleatoria X ha una funzione di distribuzione $F_X(x)$ con k parametri non noti
 - Il criterio chi-quadrato si basa sulla statistica:

$$Q = \sum_{i=1}^r \left(\frac{N_i - np_i}{\sqrt{np_i}} \right)^2$$

Che è **approssimabile con la funzione di distribuzione chi-quadrato** con $r - k - 1$ gradi di libertà

- Si sottrae:
 - 1 da r in quanto se conosciamo $r - 1$ delle probabilità p_i la rimanente probabilità può essere univocamente determinata
 - k poiché si suppone che siano k i parametri indipendenti non noti sostituiti da stimare



Criterio del chi-quadrato bilaterale

- **Definizione:**

- Per un campione **sufficientemente** numeroso di ampiezza n , il test chi-quadrato bilaterale di misura α è il seguente:

- Ipotesi H_0 : X ha una funzione di distribuzione $F_X(x)$

- Si **accetti** l'ipotesi H_0 se:

$$\chi^2_{1-\alpha/2, r-k-1} < \chi^2 < \chi^2_{\alpha/2, r-k-1}$$


- Si **rifiuti** l'ipotesi H_0 se:

$$\chi^2 < \chi^2_{1-\alpha/2, r-k-1} \text{ oppure } \chi^2 > \chi^2_{\alpha/2, r-k-1}$$

dove $\chi^2_{\alpha/2, r-k-1}$ e $\chi^2_{1-\alpha/2, r-k-1}$ sono le soluzioni di:

$$P(Q < \chi^2_{1-\alpha/2, r-k-1}) = \frac{\alpha}{2}, \quad P(Q < \chi^2_{\alpha/2, r-k-1}) = 1 - \frac{\alpha}{2}$$

Densità chi-quadrato con $r-k-1$ gradi di libertà



Applicazione su Poisson

- In un incrocio stradale sono stati registrati il numero di incidenti che si sono verificati ogni giorno per un totale di 75 giorni distinti


```
> camppois<-c(0, 3, 2, 0, 1, 2, 1, 1, 0, 1, 0, 1, 0, 0, 0,  
+ 0, 0, 1, 0, 2, 0, 1, 0, 0, 0, 0, 1, 1, 3, 2,  
+ 0, 1, 0, 1, 1, 0, 2, 3, 2, 1, 0, 0, 0, 1, 0,  
+ 0, 0, 1, 0, 3, 0, 1, 0, 2, 4, 2, 0, 1, 1, 3,  
+ 1, 0, 1, 0, 0, 0, 1, 0, 2, 4, 2, 0, 1, 2, 3)  
>  
> n<-length(camppois)  
> n  
[1] 75  
>  
> freq<-table(camppois)  
> freq  
camppois  
 0   1   2   3   4  
34  22  11   6   2
```

Applicazione su Poisson

- In un incrocio stradale sono stati registrati il numero di incidenti che si sono verificati ogni giorno per un totale di 75 giorni distinti

```
> camppois<-c(0, 3, 2, 0, 1, 2, 1, 1, 0, 1, 0, 1, 0, 0, 0,  
+ 0, 0, 1, 0, 2, 0, 1, 0, 0, 0, 0, 1, 1, 3, 2,  
+ 0, 1, 0, 1, 1, 0, 2, 3, 2, 1, 0, 0, 0, 1, 0,  
+ 0, 0, 1, 0, 3, 0, 1, 0, 2, 4, 2, 0, 1, 1, 3,  
+ 1, 0, 1, 0, 0, 0, 1, 0, 2, 4, 2, 0, 1, 2, 3)  
>  
> n<-length(camppois)  
> n  
[1] 75  
>  
> freq<-table(camppois)  
> freq  
camppois  
 0   1   2   3   4  
34  22  11   6   2
```

l'ampiezza del campione è $n = 75$ e corrisponde al numero di giorni considerati



Applicazione su Poisson

- In un incrocio stradale sono stati registrati il numero di incidenti che si sono verificati ogni giorno per un totale di 75 giorni distinti

```
> camppois<-c(0, 3, 2, 0, 1, 2, 1, 1, 0, 1, 0, 1, 0, 0, 0,  
+ 0, 0, 1, 0, 2, 0, 1, 0, 0, 0, 0, 1, 1, 3, 2,  
+ 0, 1, 0, 1, 1, 0, 2, 3, 2, 1, 0, 0, 0, 1, 0,  
+ 0, 0, 1, 0, 3, 0, 1, 0, 2, 4, 2, 0, 1, 1, 3,  
+ 1, 0, 1, 0, 0, 1, 0, 2, 4, 2, 0, 1, 2, 3)  
>  
> n<-length(camppois)  
> n  
[1] 75  
>  
> freq<-table(camppois)  
> freq  


| camppois | 0  | 1  | 2  | 3 | 4 |
|----------|----|----|----|---|---|
| 34       | 34 | 22 | 11 | 6 | 2 |

  
l'ampiezza del campione è n = 75 e corrisponde al numero di giorni considerati
```

Nei 75 giorni nell'incrocio stradale in esame si sono verificati:

- 0 incidenti in 34 giorni
- 1 incidente in 22 giorni
- 2 incidenti in 11 giorni
- 3 incidenti in 6 giorni
- 4 incidenti in 2 giorni

Applicazione su Poisson

- Vogliamo verificare se il numero di incidenti sia descrivibile con una variabile aleatoria X di Poisson di parametro λ ($\lambda > 0$), ossia

$$p_X(x) = \frac{\lambda^x}{x!} e^{-\lambda} \quad (x = 0, 1, \dots)$$

- I dati del campione permettono di ottenere una stima del parametro λ
 - Ricordando che uno stimatore corretto con varianza uniformemente minima del parametro λ di una distribuzione di Poisson risulta essere la **media campionaria**, si ha

```
> stimalambda <- mean(camppois)
> stimalambda
[1] 0.9333333
```
 - Supponiamo di considerare 4 categorie corrispondenti agli intervalli:

$$I_1 = \{0\}, \quad I_2 = (0, 1], \quad I_3 = (1, 2], \quad I_4 = (2, +\infty)$$

- Le probabilità associate agli intervalli sono:

$$p_1 = p_X(0), \quad p_2 = p_X(1), \quad p_3 = p_X(2) \quad p_4 = 1 - p_X(0) - p_X(1) - p_X(2)$$

Applicazione su Poisson

- Supponiamo di considerare 4 categorie corrispondenti agli intervalli:

$$I_1 = \{0\}, \quad I_2 = (0, 1], \quad I_3 = (1, 2], \quad I_4 = (2, +\infty)$$

- Le probabilità associate agli intervalli sono:

$$p_1 = p_X(0), \quad p_2 = p_X(1), \quad p_3 = p_X(2) \quad p_4 = 1 - p_X(0) - p_X(1) - p_X(2)$$

- Possiamo calcolarle:

```
> p<-numeric(4)
> p[1]<-dpois(0,stimalambda)
> p[2]<-dpois(1,stimalambda)
> p[3]<-dpois(2,stimalambda)
> p[4]<-1-p[1]-p[2]-p[3]
> p
[1] 0.39324072 0.36702467 0.17127818 0.06845643
```

- Il numero di elementi del campione nei quattro intervalli

```
> min(n*p[1],n*p[2],n*p[3],n*p[4])
[1] 5.134232
> r<-4
> nint<-numeric(r)
> nint[1]<-length(which(campois==0))
> nint[2]<-length(which(campois==1))
> nint[3]<-length(which(campois==2))
> nint[4]<-length(which(campois>2))
> nint
[1] 34 22 11 8
> sum(nint)
[1] 75
```

Applicazione su Poisson

- Calcoliamo χ^2 :

```
> chi2<-sum(((nint-n*p)/sqrt(n*p))^2)
> chi2
[1] 3.663227
```

$$\sum_{i=1}^r \left(\frac{n_i - np_i}{\sqrt{np_i}} \right)^2$$

- Cioè $\chi^2 = 3,663227$
- Poiché:

- il numero di categorie (o Intervalli) è $r = 4$
- Ponendo $k = 1$ poichè la probabilità di Poisson contiene un parametro non noto si ha $r - k - 1 = 2$ e considerando $\alpha = 0.01$, calcoliamo

```
> r<-4
> k<-1
> alpha<-0.01
> qchisq(alpha/2, df=r-k-1)
[1] 0.01002508
> qchisq(1-alpha/2, df=r-k-1)
[1] 10.59663
```

Applicazione su Poisson

- Calcoliamo χ^2 :

```
> chi2<-sum(((nint-n*p)/sqrt(n*p))^2)
> chi2
[1] 3.663227
```

- Cioè $\chi^2 = 3,663227$

- Poiché:

- il numero di categorie (o Intervalli) è $r = 4$

- Ponendo $k = 1$ poichè la probabilità di Poisson contiene un parametro non noto si ha $r - k - 1 = 2$ e considerando $\alpha = 0.01$, calcoliamo

```
> r<-4
> k<-1
> alpha<-0.01
> qchisq(alpha/2,df=r-k-1)
[1] 0.01002508
> qchisq(1-alpha/2,df=r-k-1)
[1] 10.59663
```

→ $\chi^2_{1-\alpha/2,r-k-1} = 0.010$ e $\chi^2_{\alpha/2,r-k-1} = 10.597$

- Essendo $0.010 < \chi^2 < 10.597$, l'ipotesi H_0 di popolazione di Poisson **può essere accettata**

Applicazione sulla Normale

- Un urbanista è interessato alla superficie media μ delle abitazioni di una certa città
- A questo scopo osserva un campione di 50 appartamenti

```
> campnorm<-c(112.6, 118.2, 124.8, 122.1, 137.5, 106.7, 123.7,  
+ 127.3, 123.2, 125.1, 120.8, 112.9, 117.0, 128.1, 102.9, 119.1,  
+ 127.2, 124.8, 118.0, 131.4, 117.0, 118.2, 125.8, 116.2, 118.5,  
+ 120.8, 127.1, 125.0, 131.2, 120.2, 126.0, 119.2, 112.4, 124.6,  
+ 117.7, 116.1, 125.3, 115.5, 129.6, 119.1, 130.6, 125.3, 128.7,  
+ 134.6, 124.5, 117.2, 126.1, 116.1, 116.0, 125.6)  
> n<-length(campnorm)  
> n  
[1] 50  
>  
> m<-mean(campnorm)  
> m  
[1] 121.872  
> d<-sd(campnorm)  
> d  
[1] 6.735469
```

Applicazione sulla Normale

- Un urbanista è interessato alla superficie media μ delle abitazioni di una certa città
- A questo scopo osserva un campione di 50 appartamenti

```
> campnorm<-c(112.6, 118.2, 124.8, 122.1, 137.5, 106.7, 123.7,  
+ 127.3, 123.2, 125.1, 120.8, 112.9, 117.0, 128.1, 102.9, 119.1,  
+ 127.2, 124.8, 118.0, 131.4, 117.0, 118.2, 125.8, 116.2, 118.5,  
+ 120.8, 127.1, 125.0, 131.2, 120.2, 126.0, 119.2, 112.4, 124.6,  
+ 117.7, 116.1, 125.3, 115.5, 129.6, 119.1, 130.6, 125.3, 128.7,  
+ 134.6, 124.5, 117.2, 126.1, 116.1, 116.0, 125.6)  
> n<-length(campnorm)  
> n  
[1] 50  
>  
> m<-mean(campnorm)  
→ Media Campionaria  
> m  
[1] 121.872  
> d<-sd(campnorm)  
→ Deviazione Standard Campionaria  
> d  
[1] 6.735469
```

Applicazione sulla Normale

- Vogliamo verificare se la popolazione da cui proviene il campione può essere descritta da una variabile aleatoria X di densità normale
 - Applichiamo il test chi-quadrato di misura $\alpha = 0.05$

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad x \in \mathbb{R} \quad (\mu \in \mathbb{R}, \sigma > 0)$$

- Supponiamo di suddividere l'insieme dei valori che X può assumere in $r = 5$ sottoinsiemi I_1, I_2, \dots, I_5 in modo che risulti
 - Che la probabilità che X assuma un valore appartenente a I_i ($i = 1, 2, \dots, 5$) sia uguale a $p_i = 0.2$
- Ricordando che:
 - Lo stimatore di μ è la media campionaria
 - Lo stimatore di σ^2 è la varianza campionaria
 - Utilizzando i quantili della normale possiamo determinare i sottoinsiemi I_1, I_2, \dots, I_5

Applicazione sulla Normale

- Utilizzando i quantili della normale possiamo determinare i sottoinsiemi I_1, I_2, \dots, I_5

```
> a<-numeric(4)
> for(i in 1:4)
+ a[i]<-qnorm(0.2*i,mean=m,sd=d)
> a
[1] 116.2033 120.1656 123.5784 127.5407
```

- Si ha che gli intervalli sono:

$$I_1 = (-\infty, 116.20), \quad I_2 = [116.2, 120.17), \quad I_3 = [120.17, 123.58), \\ I_4 = [123.58, 127.54), \quad I_5 = [127.54, +\infty).$$

- Determinare il numero di elementi del campione che cadono nei singoli intervalli:

```
> r<-5
> nint<-numeric(r)
> nint[1]<-length(which(campnorm<a[1]))
> nint[2]<-length(which((campnorm)>=a[1])&(campnorm<a[2]))
> nint[3]<-length(which((campnorm)>=a[2])&(campnorm<a[3]))
> nint[4]<-length(which((campnorm)>=a[3])&(campnorm<a[4]))
> nint[5]<-length(which(campnorm>=a[4]))
> nint
[1] 10 11 5 16 8
> sum(nint)
[1] 50
```

Le frequenze degli intervalli sono:

$$n_1 = 10 \quad n_2 = 11 \quad n_3 = 5 \quad n_4 = 16 \quad n_5 = 8$$

Applicazione sulla Normale

- Calcoliamo χ^2 :

```
> chi2<-sum(((nint-n*0.2)/sqrt(n*0.2))^2)
> chi2
[1] 6.6
```

$$\sum_{i=1}^r \left(\frac{n_i - np_i}{\sqrt{np_i}} \right)^2$$

- Cioè $\chi^2 = 6.6$

- Poiché:

- il numero di categorie (intervalli) è $r = 5$
- Ponendo $k = 3$ poiché la probabilità Normale contiene due parametri non noti

si ha $r - k - 1 = 2$ e considerando $\alpha = 0.05$, calcoliamo

```
> r<-5
> k<-2
> alpha<-0.05
> qchisq(alpha/2, df=r-k-1)
[1] 0.05063562
> qchisq(1-alpha/2, df=r-k-1)
[1] 7.377759
```

$$\chi^2_{1-\alpha/2, r-k-1} = 0.0506 \text{ e } \chi^2_{\alpha/2, r-k-1} = 7.378$$

Essendo $0.0506 < \chi^2 < 7.378$, l'ipotesi H_0 di popolazione normale può essere accettata